

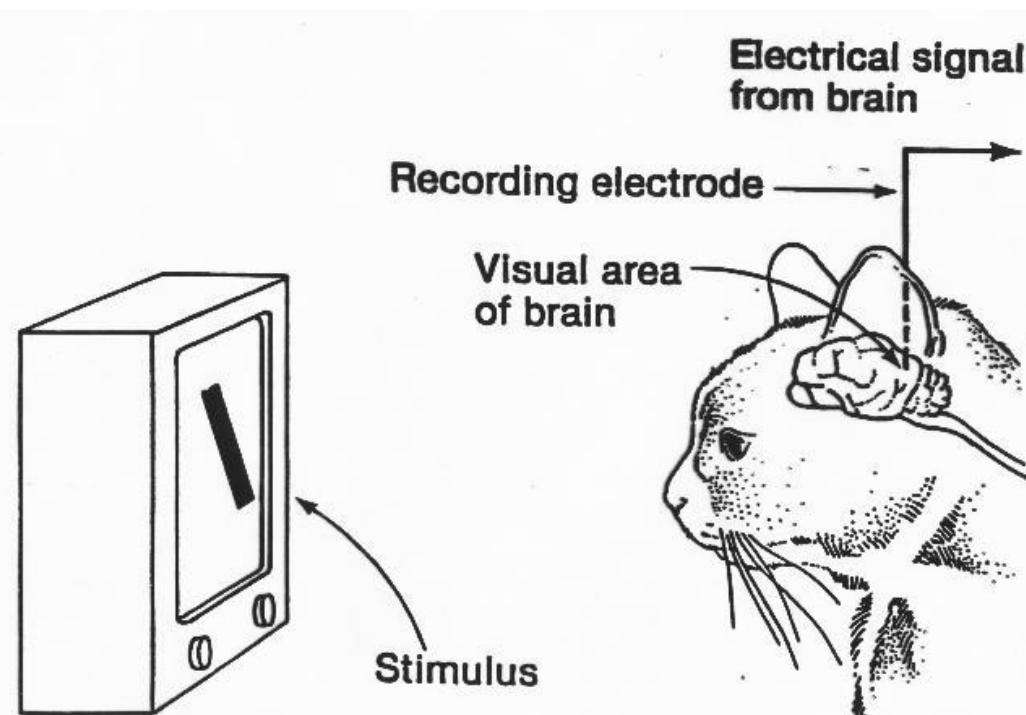
# Visión Computacional

Ivan Sipiran

# La revolución es la convolución

Pero no una nueva revolución

Hubel and Wiesel, 1959



Los experimentos mostraron que ciertas células en el córtex visual responden a estímulos específicos. Formalmente, la respuesta es obtenida por una operación de convolución entre la señal de entrada y la funcionalidad de la célula.

# Qué es convolución?

- Es una operación lineal que transforma el contenido de la imagen usando un elemento estructural llamado *kernel*.
- Técnicamente es una función lineal

10	5	3
4	5	1
1	1	7

Some function  

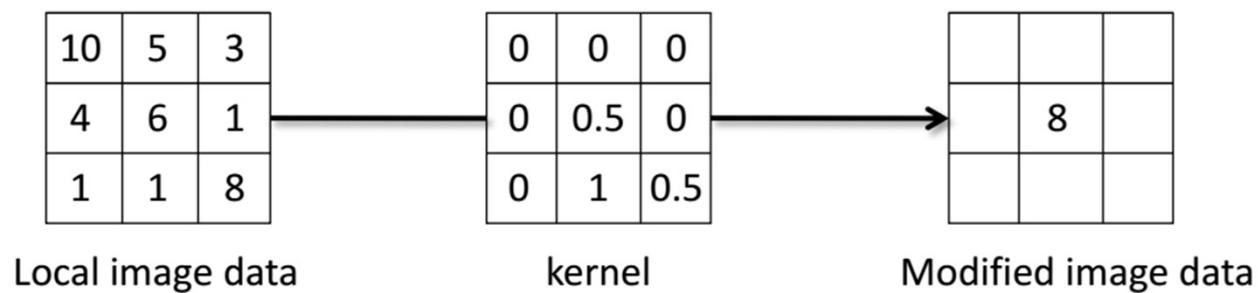

Local image data

7		

Modified image data

# Qué es convolución?

- En general, un píxel es reemplazado como la combinación de sus vecinos
- El kernel contiene los pesos para computar esa combinación



# Convolución

- Sea  $F$  una imagen,  $H$  (size  $2k + 1, 2k + 1$ ) un kernel, y  $G$  la imagen de salida

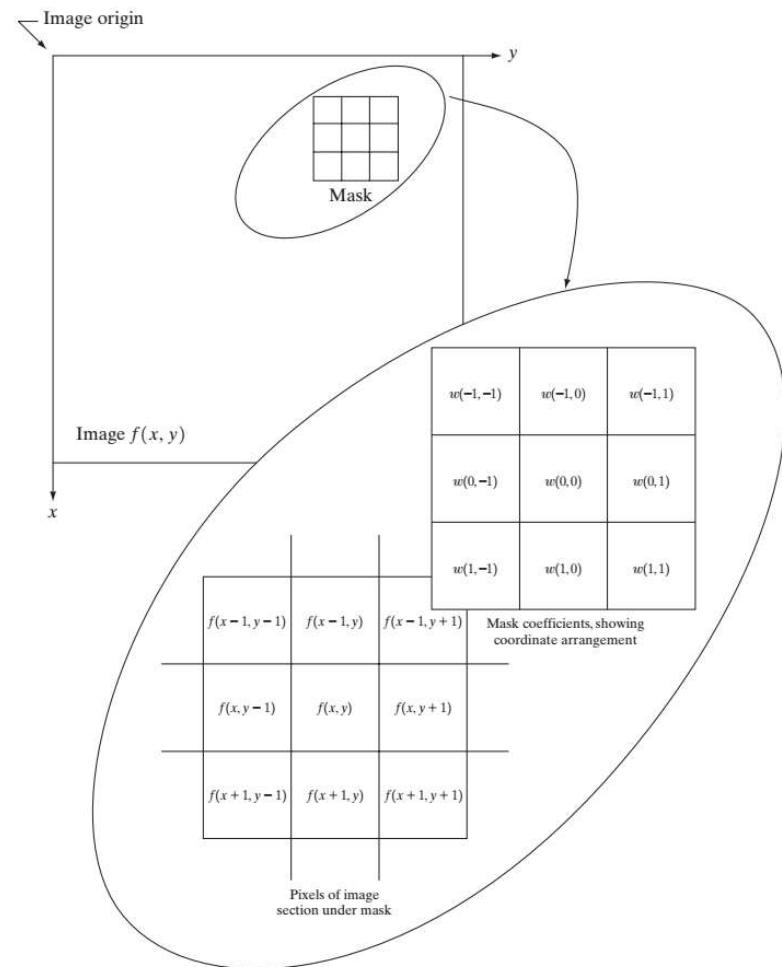
$$G[i, j] = \sum_{u=-k}^k \sum_{v=-k}^k H[u, v]F[i - u, j - v]$$

- Convolución es asociativa y conmutativa

$$G = H * F$$

# Convolución

- Es una operación píxel a píxel
- El kernel se desliza en la imagen mientras computa la transformación lineal local.



# Convolución: Ejemplo

$$\begin{array}{|c|c|c|c|c|} \hline 1 & 2 & 3 & 2 & 1 \\ \hline 3 & 2 & 2 & 1 & 3 \\ \hline 2 & 1 & 3 & 2 & 3 \\ \hline 2 & 3 & 3 & 1 & 2 \\ \hline 3 & 1 & 2 & 2 & 3 \\ \hline \end{array} * \begin{array}{|c|c|c|} \hline 1 & 1 & 1 \\ \hline 1 & 1 & 1 \\ \hline 1 & 1 & 1 \\ \hline \end{array} =$$

# Convolución: Ejemplo

$$\begin{array}{|c|c|c|} \hline 1 & 2 & 3 \\ \hline 3 & 2 & 2 \\ \hline 2 & 1 & 3 \\ \hline 2 & 3 & 3 \\ \hline 3 & 1 & 2 \\ \hline \end{array} \quad * \quad \begin{array}{|c|c|c|} \hline 1 & 1 & 1 \\ \hline 1 & 1 & 1 \\ \hline 1 & 1 & 1 \\ \hline \end{array} \quad = \quad \begin{array}{|c|c|c|} \hline 20 & & \\ \hline & & \\ \hline & & \\ \hline \end{array}$$

# Convolución: Ejemplo

$$\begin{array}{|c|c|c|c|c|} \hline 1 & 2 & 3 & 2 & 1 \\ \hline 3 & 2 & 2 & 1 & 3 \\ \hline 2 & 1 & 3 & 2 & 3 \\ \hline 2 & 3 & 3 & 1 & 2 \\ \hline 3 & 1 & 2 & 2 & 3 \\ \hline \end{array} * \begin{array}{|c|c|c|} \hline 1 & 1 & 1 \\ \hline 1 & 1 & 1 \\ \hline 1 & 1 & 1 \\ \hline \end{array} = \begin{array}{|c|c|c|} \hline 20 & 18 & \\ \hline & & \\ \hline & & \\ \hline \end{array}$$

# Convolución: Ejemplo

$$\begin{array}{|c|c|c|c|c|} \hline 1 & 2 & 3 & 2 & 1 \\ \hline 3 & 2 & 2 & 1 & 3 \\ \hline 2 & 1 & 3 & 2 & 3 \\ \hline 2 & 3 & 3 & 1 & 2 \\ \hline 3 & 1 & 2 & 2 & 3 \\ \hline \end{array} * \begin{array}{|c|c|c|} \hline 1 & 1 & 1 \\ \hline 1 & 1 & 1 \\ \hline 1 & 1 & 1 \\ \hline \end{array} = \begin{array}{|c|c|c|} \hline 20 & 18 & 19 \\ \hline & & \\ \hline & & \\ \hline & & \\ \hline \end{array}$$

The diagram illustrates a convolution operation. It shows three input matrices (the first two are 5x5, the third is 3x3) being multiplied by a 3x3 kernel. The result is a single output matrix of size 3x3. The highlighted element in the input matrices (the top-left 3x3 block of the first matrix and the entire 3x3 kernel) and the circled element in the output matrix (the bottom-right element) represent the calculation of the output value 19.

# Convolución: Ejemplo

$$\begin{array}{|c|c|c|c|c|} \hline 1 & 2 & 3 & 2 & 1 \\ \hline 3 & 2 & 2 & 1 & 3 \\ \hline 2 & 1 & 3 & 2 & 3 \\ \hline 2 & 3 & 3 & 1 & 2 \\ \hline 3 & 1 & 2 & 2 & 3 \\ \hline \end{array} * \begin{array}{|c|c|c|} \hline 1 & 1 & 1 \\ \hline 1 & 1 & 1 \\ \hline 1 & 1 & 1 \\ \hline \end{array} = \begin{array}{|c|c|c|} \hline 20 & 18 & 19 \\ \hline 20 & 18 & 19 \\ \hline 20 & 18 & 21 \\ \hline \end{array}$$

# Convolución: Ejemplo

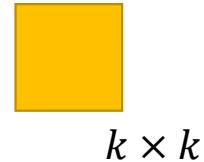
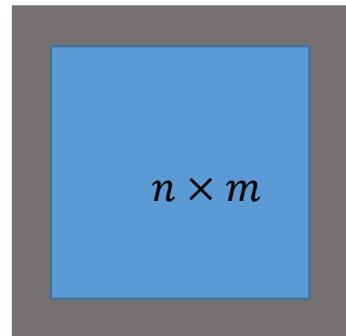
- Has notado que se pierde información?

$$\begin{array}{|c|c|c|} \hline & & \\ \hline \end{array} \quad \begin{array}{|c|c|c|} \hline 1 & 2 & \\ \hline 3 & 2 & \\ \hline 2 & 1 & \\ \hline 2 & 3 & \\ \hline 3 & 1 & \\ \hline \end{array} \quad * \quad \begin{array}{|c|c|c|} \hline 1 & 1 & 1 \\ \hline 1 & 1 & 1 \\ \hline 1 & 1 & 1 \\ \hline \end{array} \quad = \quad \begin{array}{|c|c|c|} \hline 20 & 18 & 19 \\ \hline 20 & 18 & 19 \\ \hline 20 & 18 & 21 \\ \hline \end{array}$$

- Imagen de entrada es de 5x5 y la salida es de 3x3
- No podemos aplicar el kernel en ciertas posiciones (bordes)

# Convolución: padding

- Estrategias para el problema de los bordes:
  - Tomar la salida, sin cambios. Podríamos estar perdiendo información valiosa.
  - Padding: llenar la imagen de entrada con ceros, de tal forma que la salida tenga el mismo tamaño que la entrada



$$(n + k - 1) \times (m + k - 1)$$

# Efecto de la convolución

- Veamos algunos ejemplos de convolución



$$\text{Kernel} = \frac{1}{25}$$

1	1	1	1	1
1	1	1	1	1
1	1	1	1	1
1	1	1	1	1
1	1	1	1	1

Qué operación estamos realizando?

Promedio

# Efecto de la convolución

- Veamos algunos ejemplos de convolución

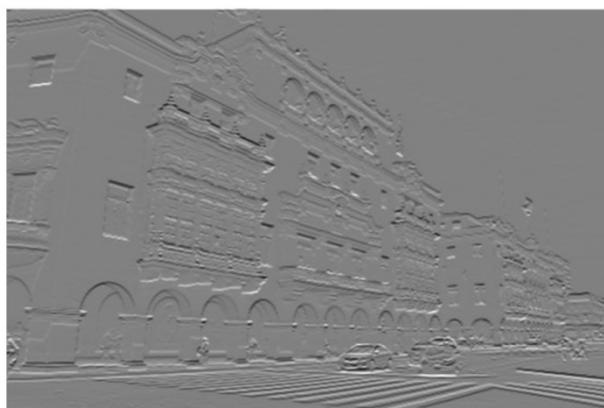


Kernel = kernel promedio de tamaño 21



# Efecto de la convolución

- Veamos algunos ejemplos de convolución



$$\text{Kernel} = \begin{array}{|c|c|c|}\hline -1 & 0 & 1 \\ \hline -2 & 0 & 2 \\ \hline -1 & 0 & 1 \\ \hline \end{array}$$

Sobel, vertical edges

# Deep Learning

*Capas  
Convolucionales*



# Imágenes son datos

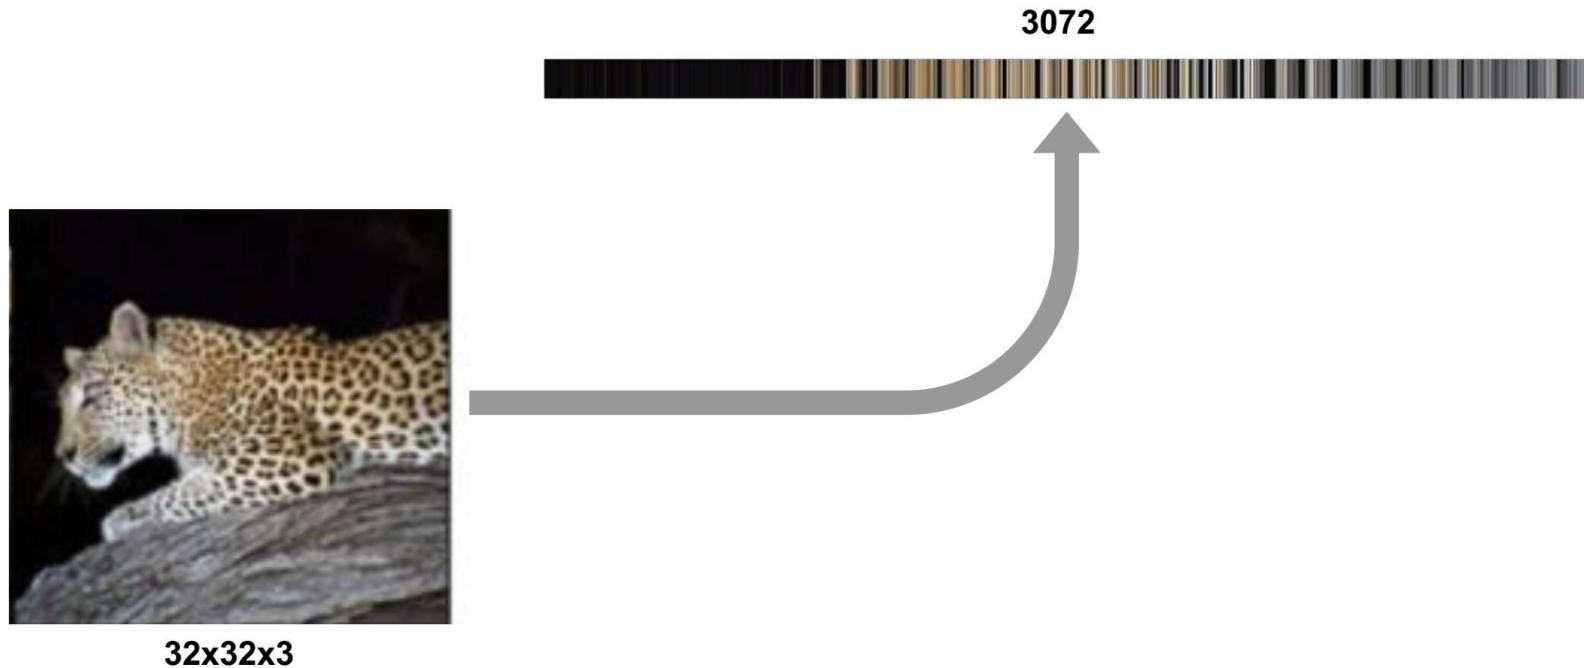
- Si queremos implementar clasificación de imágenes con un MLP



**32x32x3**

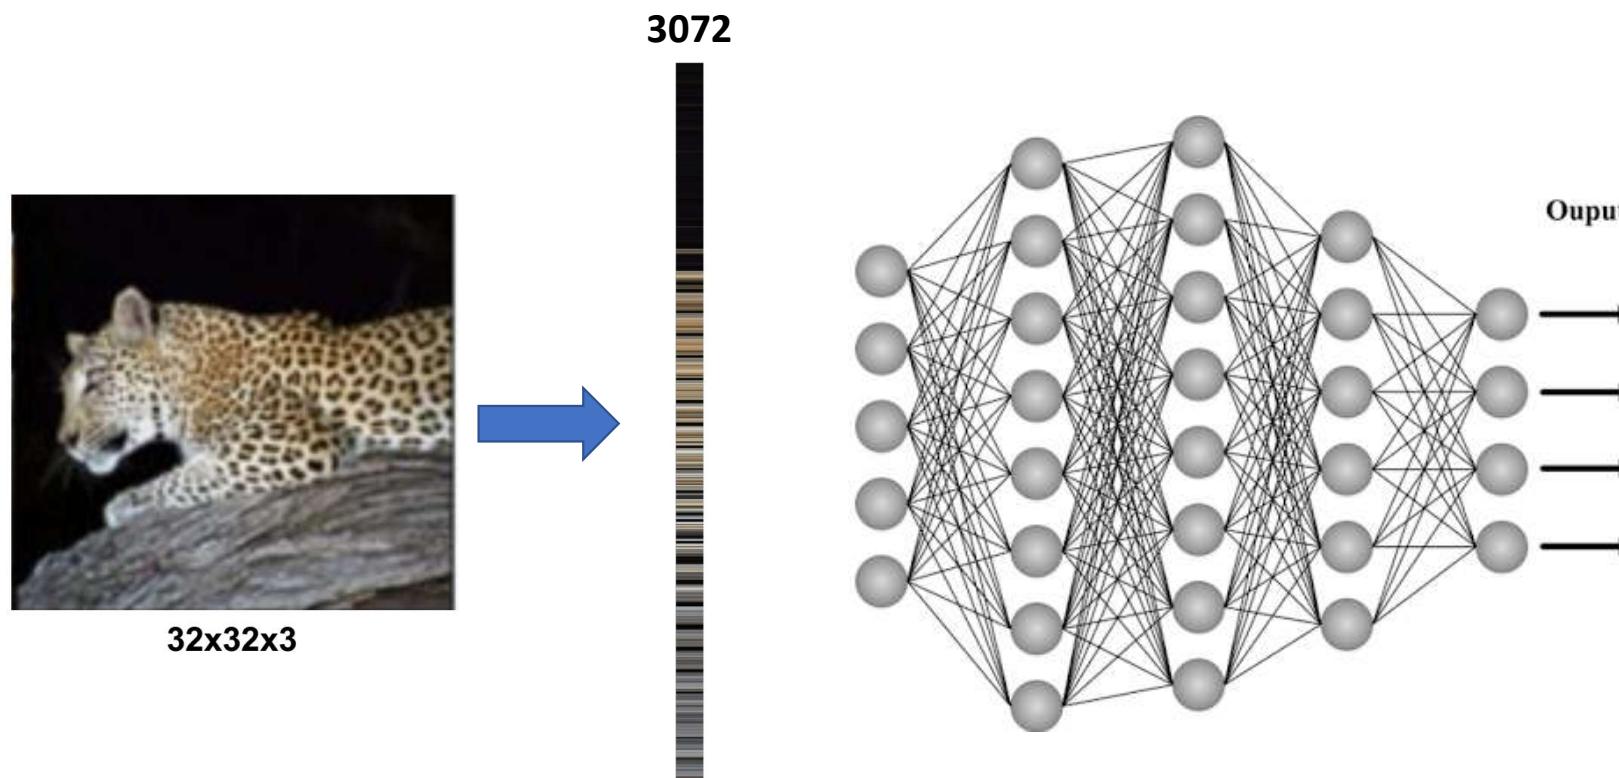
# Imágenes son datos

- Si queremos implementar clasificación de imágenes con un MLP



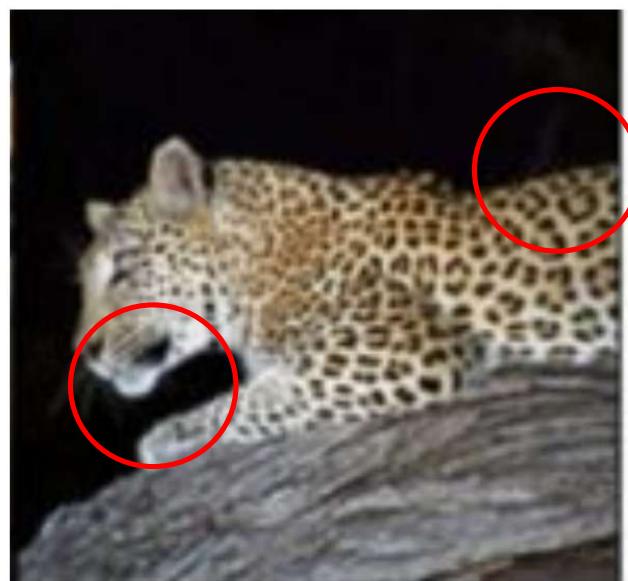
# Imágenes son datos

- Si queremos implementar clasificación de imágenes con un MLP



# Imágenes son datos

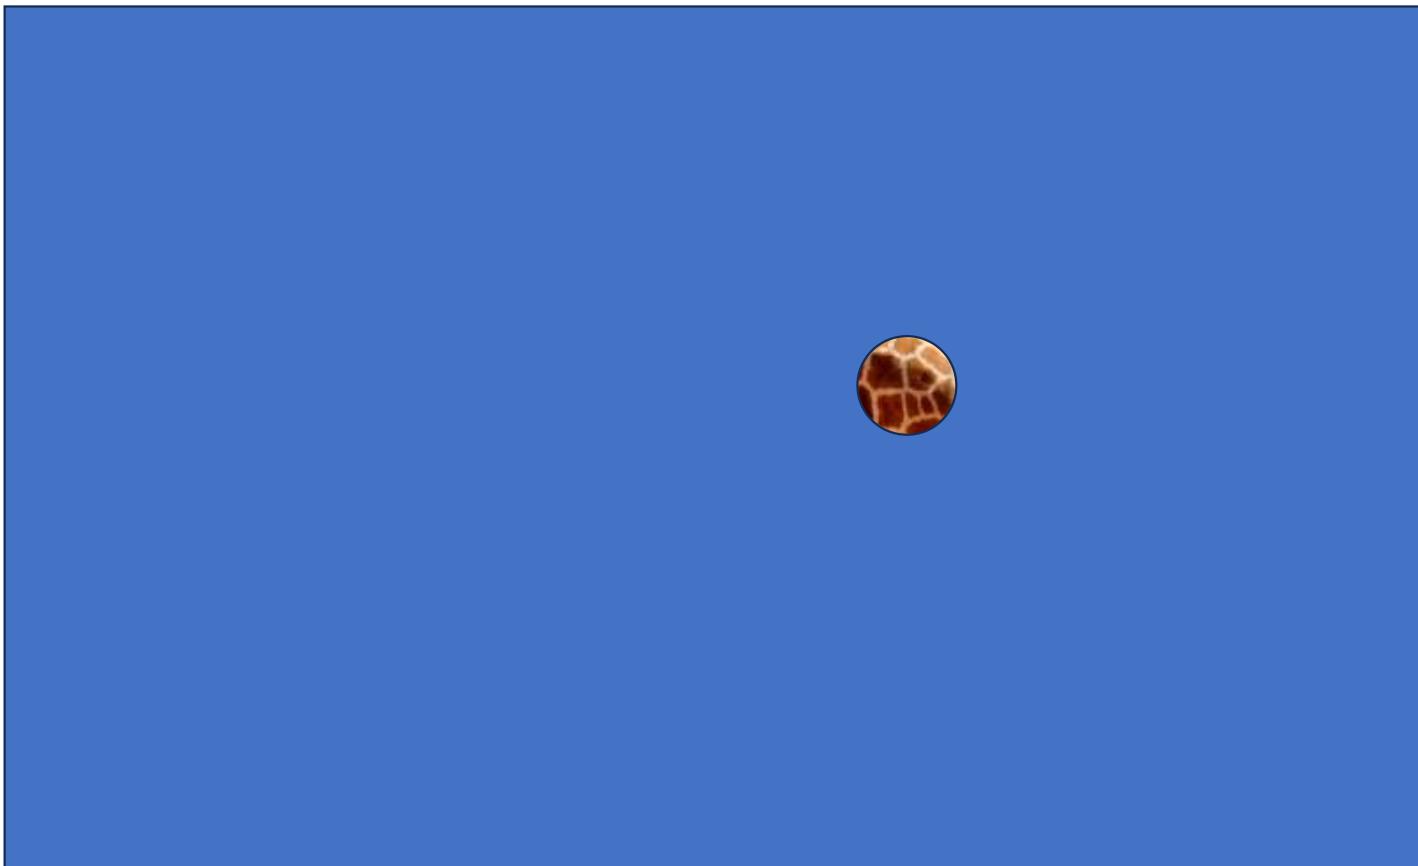
- Si queremos implementar clasificación de imágenes con un MLP
- La cantidad de parámetros es enorme
- Un MLP intenta encontrar todas las posibles relaciones entre los píxeles de entrada. Eso está bien?



Imágenes son datos



Imágenes son datos



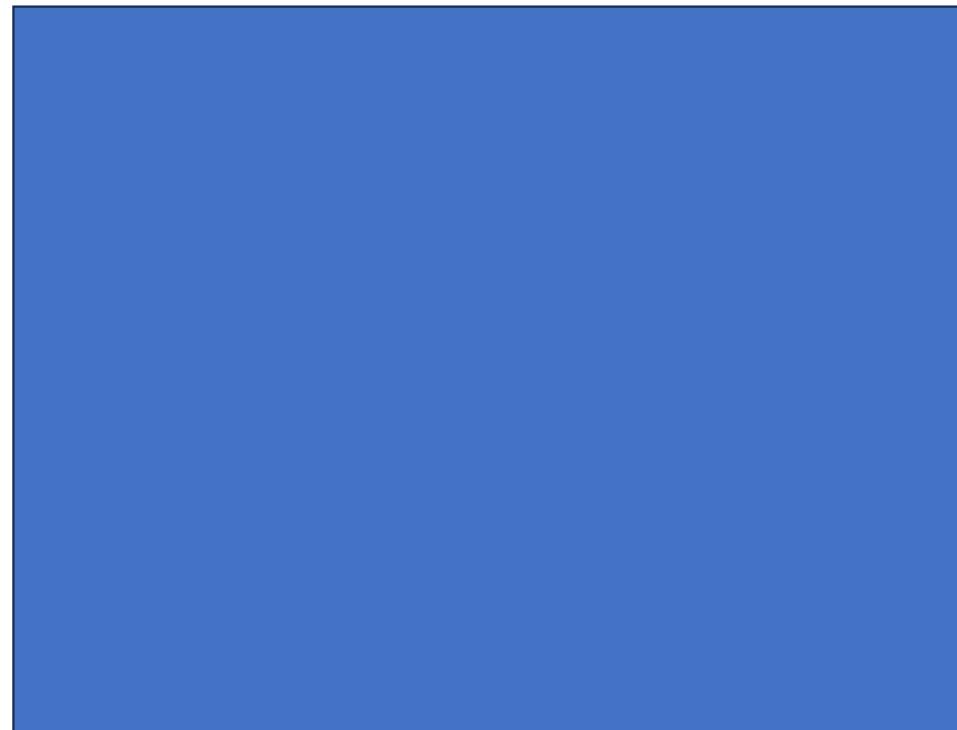
# Imágenes son datos



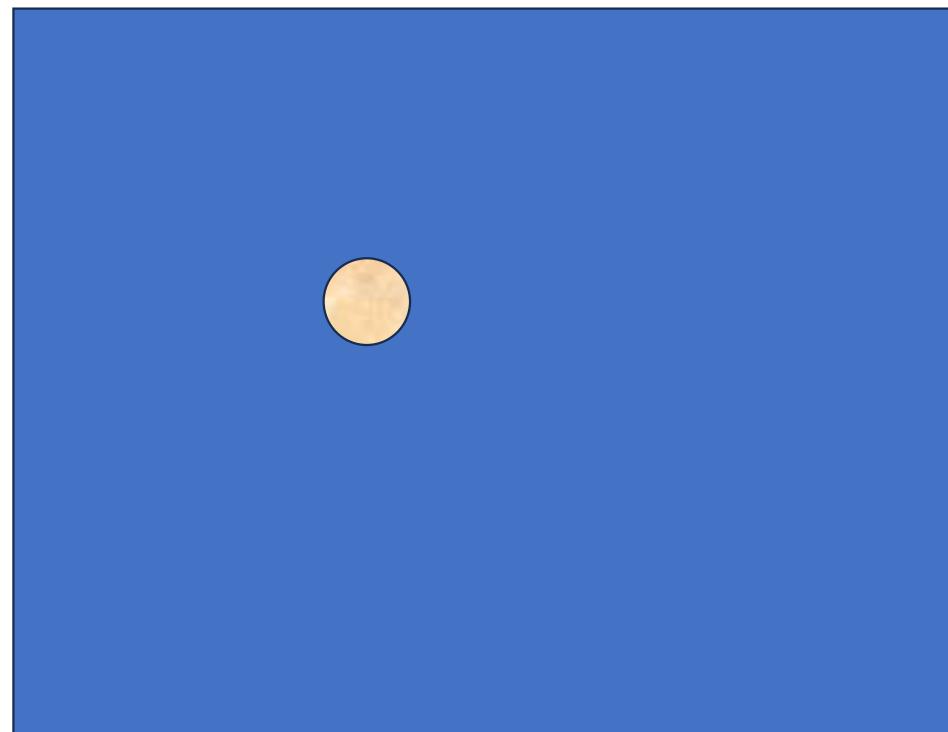
Imágenes son datos



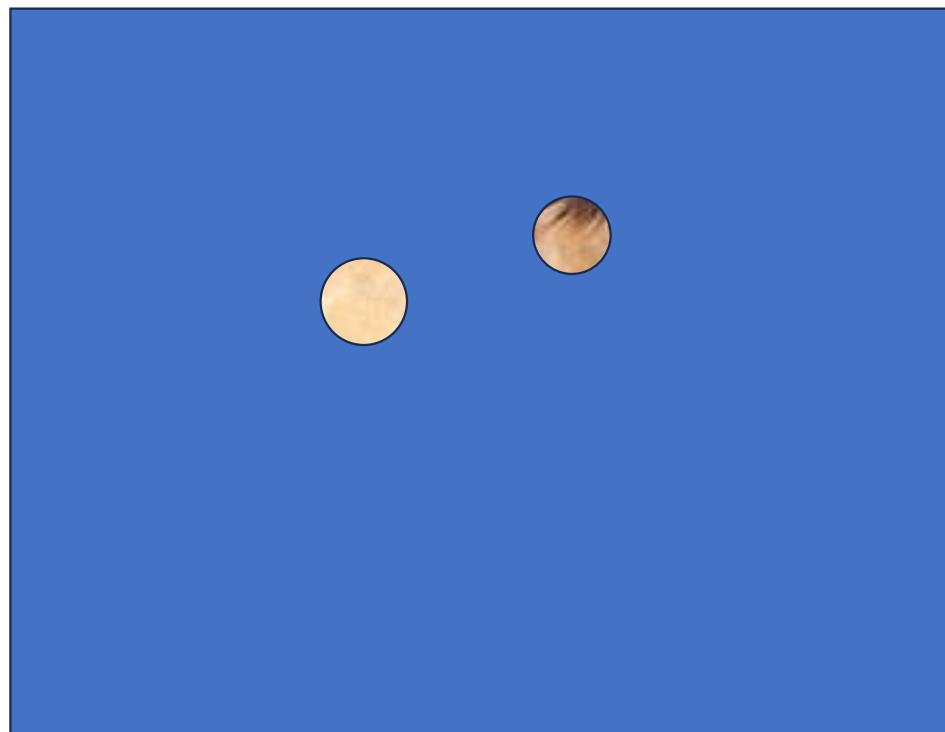
Imágenes son datos



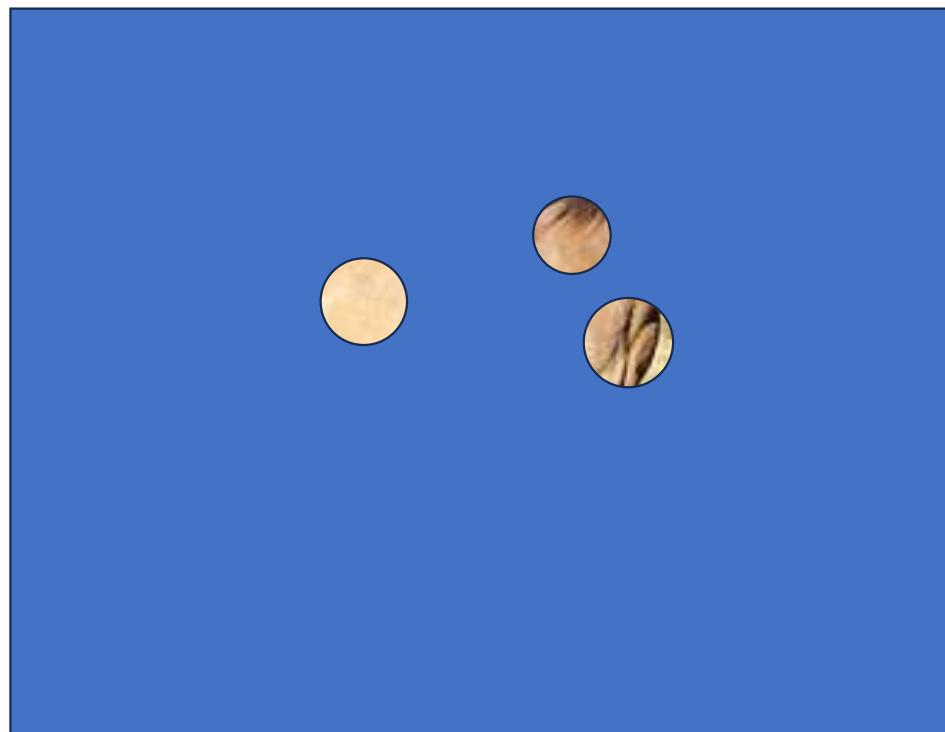
Imágenes son datos



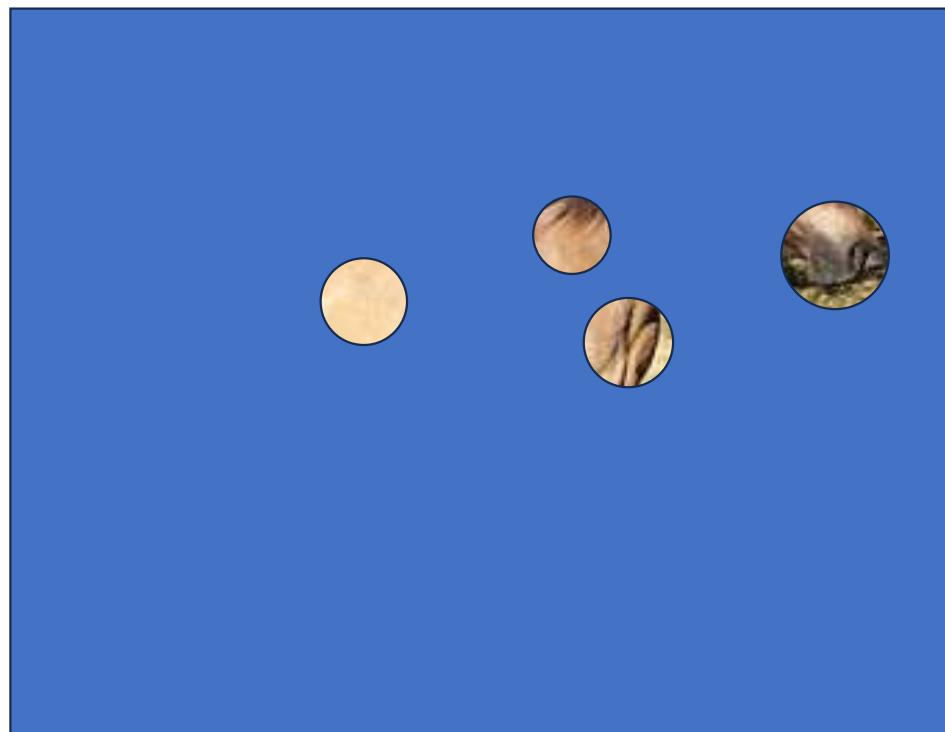
Imágenes son datos



Imágenes son datos



Imágenes son datos



Imágenes son datos



# Imágenes son datos



Mucha información visual estructural es local.

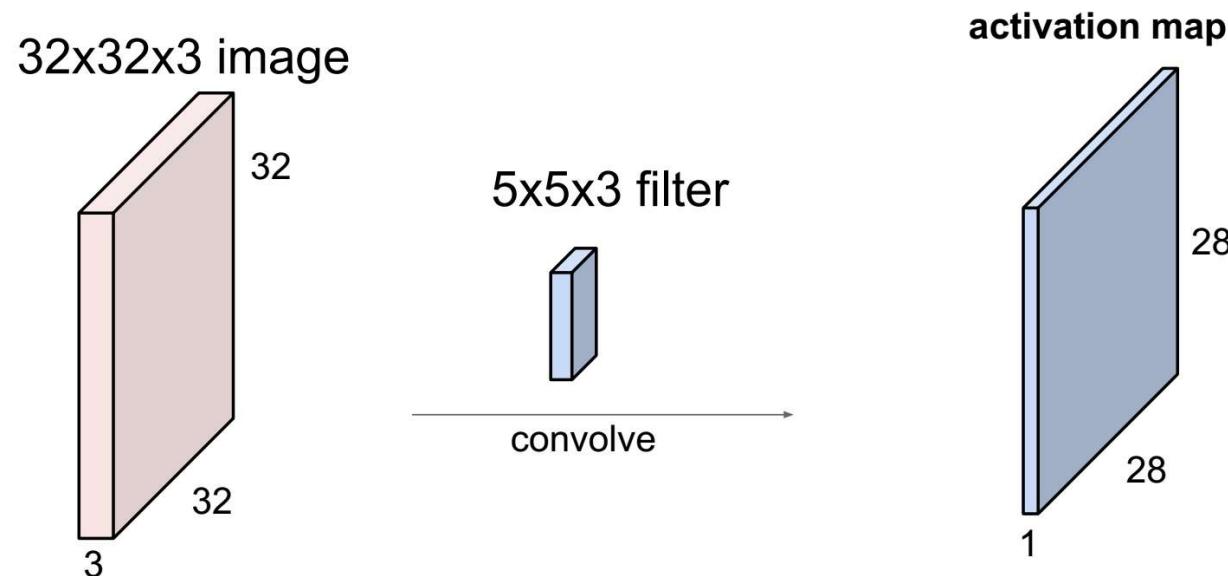
Píxeles en regiones lejanas podrían no relacionarse a través de contenido de interés

Ya conocemos una operación que computa información local

**Convolución!**

# Capas convolucionales

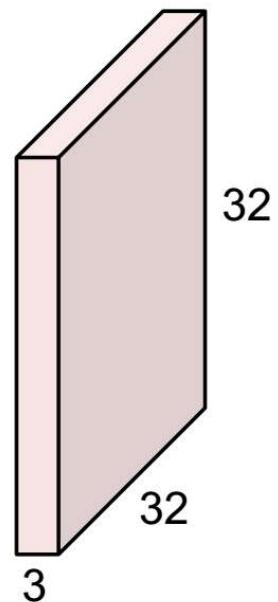
- Una capa convolucional está compuesta de un conjunto de kernels
- Cada kernel se convoluciona con la entrada y genera un mapa de activación (también conocido como mapa característico)



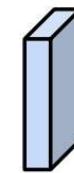
# Capas convolucionales

- La profundidad del input es siempre la profundidad de los kernels

32x32x3 image

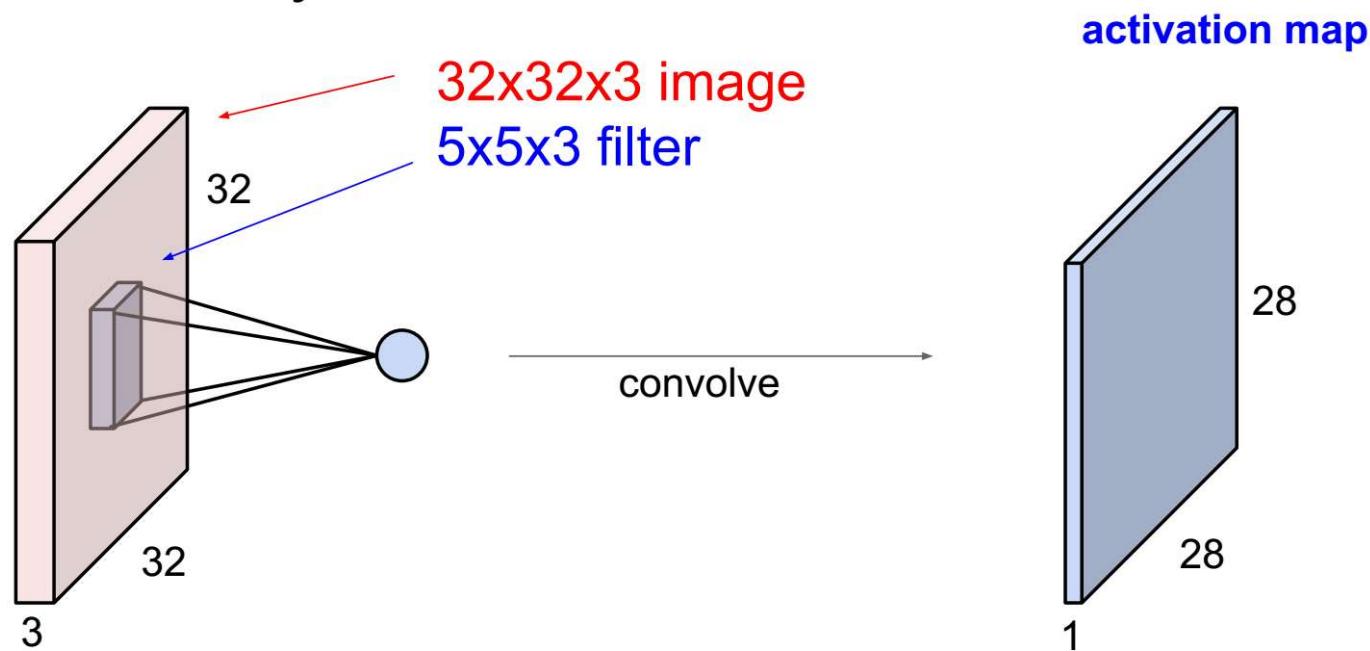


5x5x3 filter



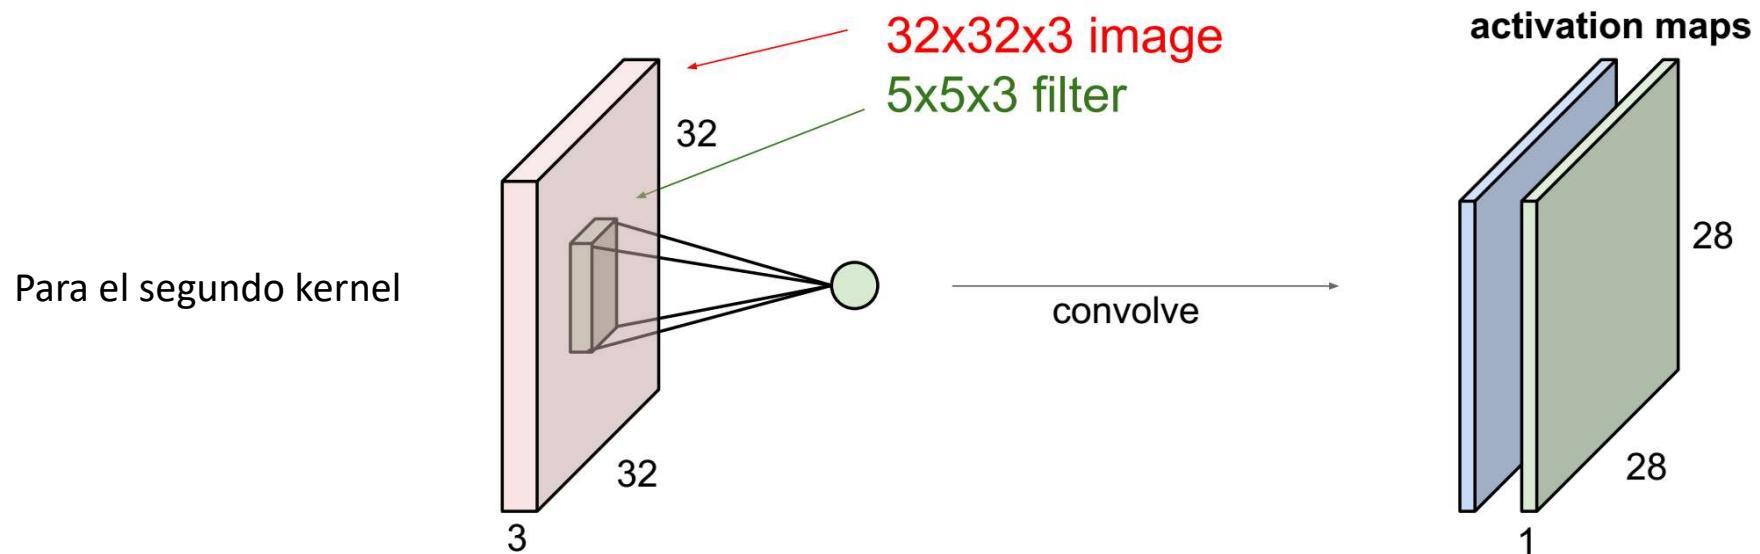
# Capas convolucionales

- Podemos tener varios kernels en la misma capa
- Cada uno genera un mapa de activación



# Capas convolucionales

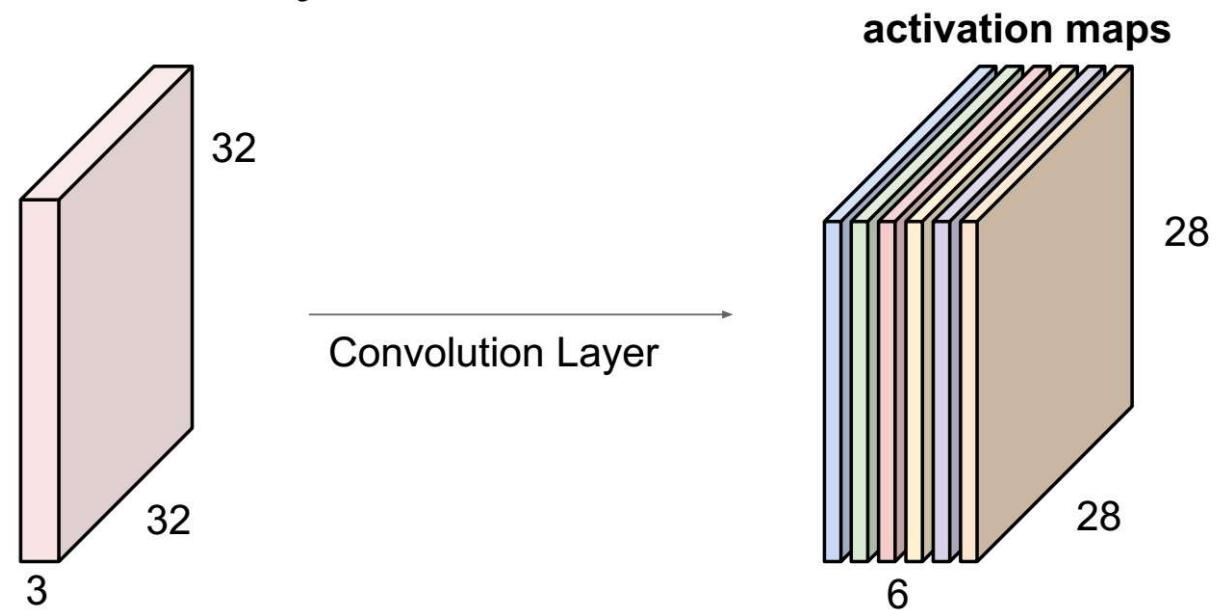
- Podemos tener varios kernels en la misma capa
- Cada uno genera un mapa de activación



# Capas convolucionales

- Podemos tener varios kernels en la misma capa
- Cada uno genera un mapa de activación

Si usamos seis kernels, la salida tendrá  
Profundidad seis



# Capas convolucionales

- Parámetros
  - En una capa lineal, los parámetros son pesos y biases, y la operación de la capa es

$$z_L = X_{L-1} \cdot W_L + b_L$$

- La operación lineal es el producto punto entre el input y los pesos
- En la capa convolucional tenemos

$$z_L = X_{L-1} * W_L + b_L$$

en donde la operación lineal es la convolución, y la salida es el mapa de activación.  $W_L$  representa el kernel y el bias es un solo número.

# Capas convolucionales

- Cuántos parámetros hay en una capa convolucional de  $m$  kernels de dimensión  $k \times k \times d$ ?

$$m \times k \times k \times d + m$$


# Deep Learning

*Hyper-parámetros y  
Pooling*



# Parámetros

- Para construir una capa convolucional necesitamos
  - $K$ : número de kernels en la capa
  - $F$ : extensión espacial del kernel
  - $S$ : el stride (número de píxeles para mover la ventana de convolución)
  - $P$ : el número  $f$  de píxels para padding

Si el volumen de entrada tiene tamaño  $W$ , el tamaño del mapa de activación es

$$\frac{W - F + 2P}{S} + 1$$

# Ejemplo

Red channel

Input Volume (+pad 1) (7x7x3)	Filter W0 (3x3x3)
x[:, :, 0]	w0[:, :, 0]
0 0 0 0 0 0 0 0 0 2 1 0 2 0 0 1 1 1 2 2 0 0 2 1 2 1 2 0 0 0 1 1 0 1 0 0 1 0 0 1 0 0 0 0 0 0 0 0 0	1 1 1 1 1 0 0 -1 -1 1 0 0 1 0 0 1 1 0
x[:, :, 1]	w0[:, :, 1]
0 0 0 0 0 0 0 0 1 2 0 0 1 0 0 1 1 2 1 2 0 0 2 1 0 0 1 0 0 2 1 2 1 0 0 0 1 2 1 2 1 0 0 0 0 0 0 0 0	1 0 0 -1 0 1 0 0 -1
x[:, :, 2]	w0[:, :, 2]
0 0 0 0 0 0 0 0 1 1 0 2 0 0 0 2 2 0 2 1 0 0 2 0 2 0 0 0 0 1 1 0 2 2 0 0 0 0 0 0 0 0	1 -1 1 -1 0 1 0 0 -1

Green channel

Filter W1 (3x3x3)	Output Volume (3x3x2)
w1[:, :, 0]	o[:, :, 0]
-1 0 -1 0 -1 -1 0 1 0	-1 5 2 5 14 10 5 9 4
w1[:, :, 1]	o[:, :, 1]
1 -1 0 0 -1 -1 1 1 1	-1 5 -3 -3 1 -8 -4 -4 -2
w1[:, :, 2]	o[:, :, 2]
0 0 1 -1 0 1 -1 -1 1	0 0 1

Bias b0 (1x1x1)  
b0[:, :, 0]

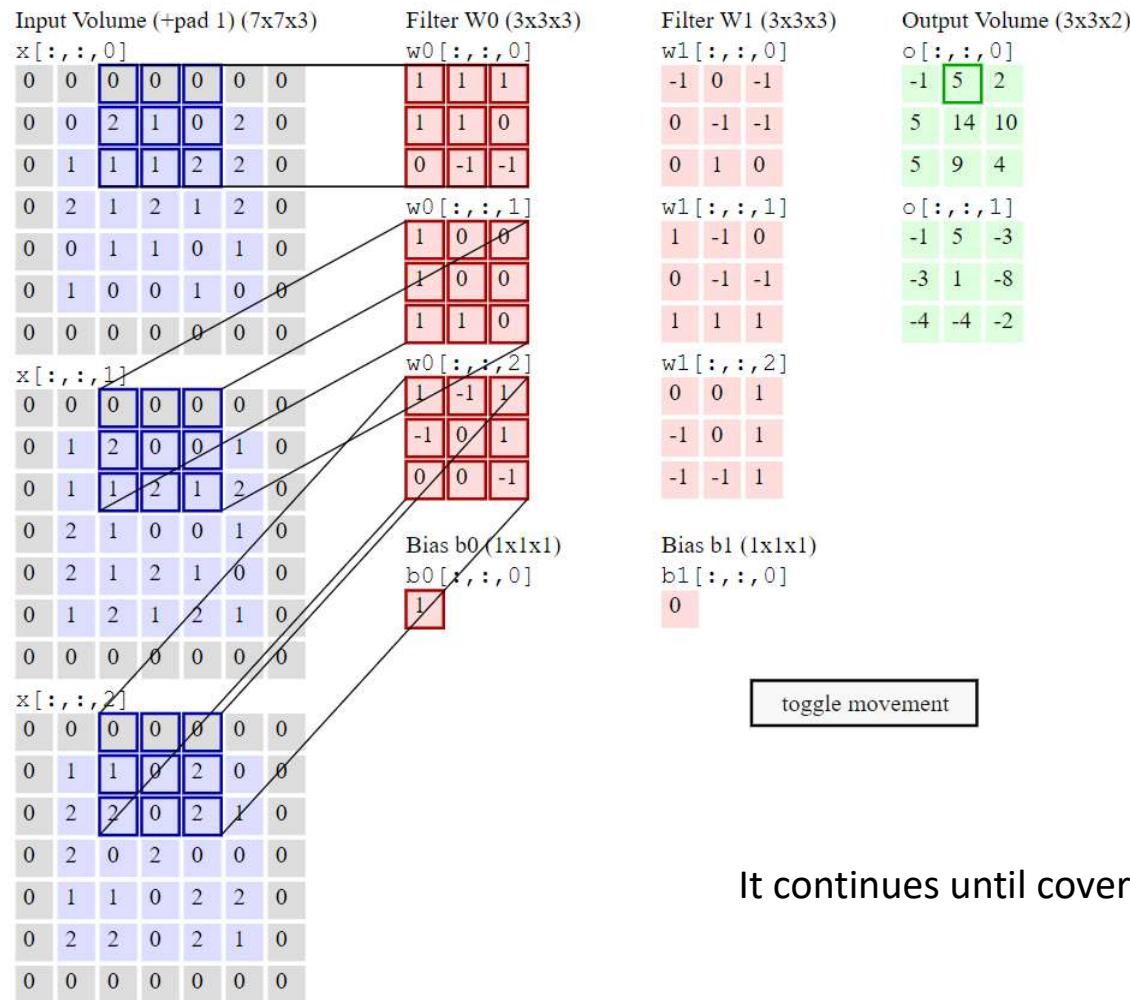
Bias b1 (1x1x1)  
b1[:, :, 0]

0

toggle movement

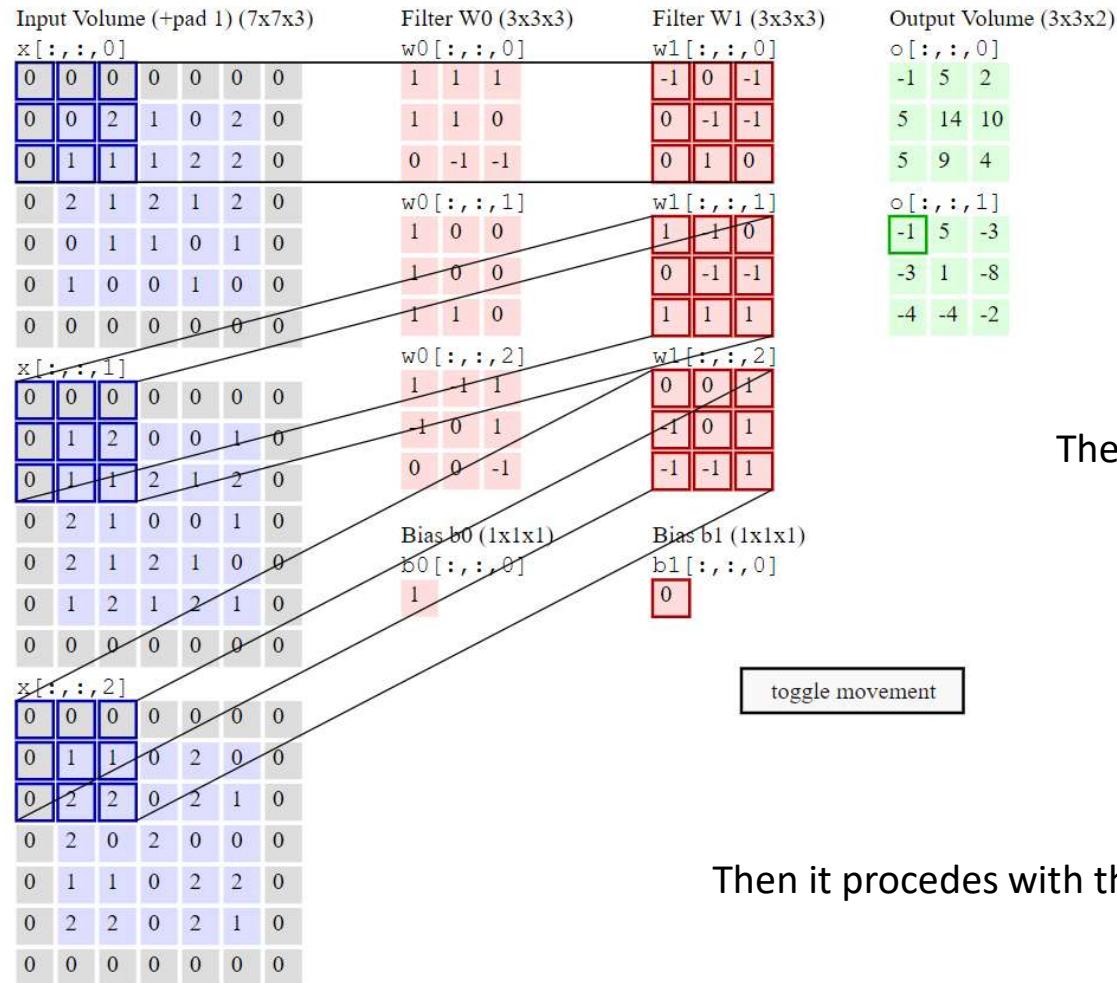
Blue channel

# Ejemplo



It continues until covering the complete image

# Ejemplo



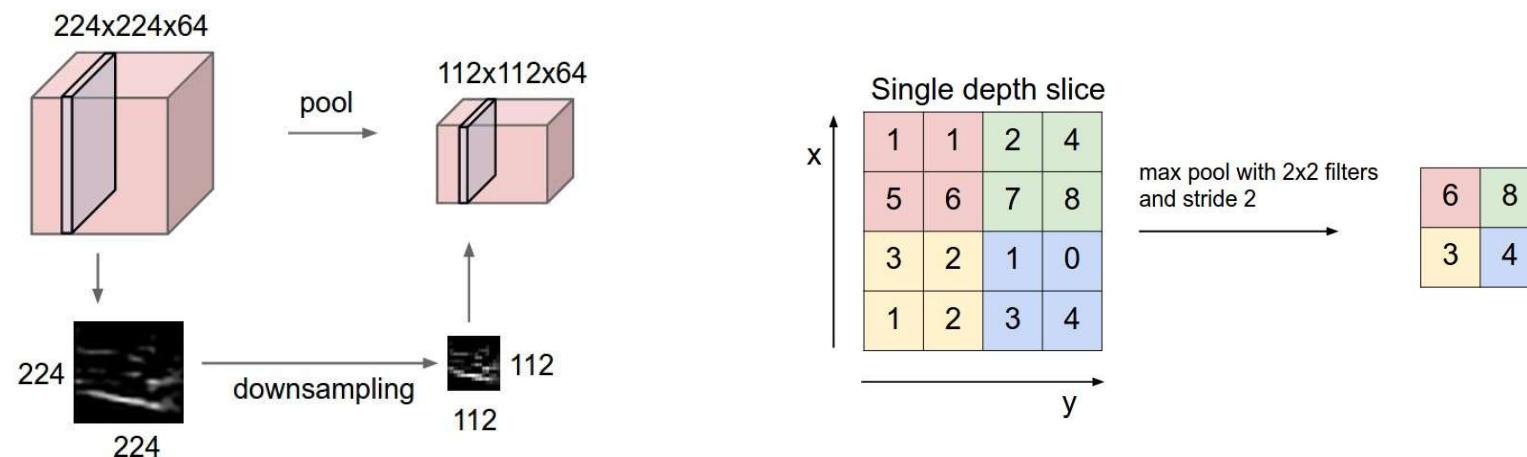
The output volumen is 3x3x2

toggle movement

Then it procedes with the second kernel

# Capa de Pooling

- Reduce el tamaño espacial de la representación
  - Reduce la cantidad de parámetros
  - Reduce el cómputo
  - Permite encontrar representaciones multi-escala en las imágenes
- Max pooling, tamaño 2, stride 2 es la elección típica



# Deep Learning

*Ejemplo Convolución*



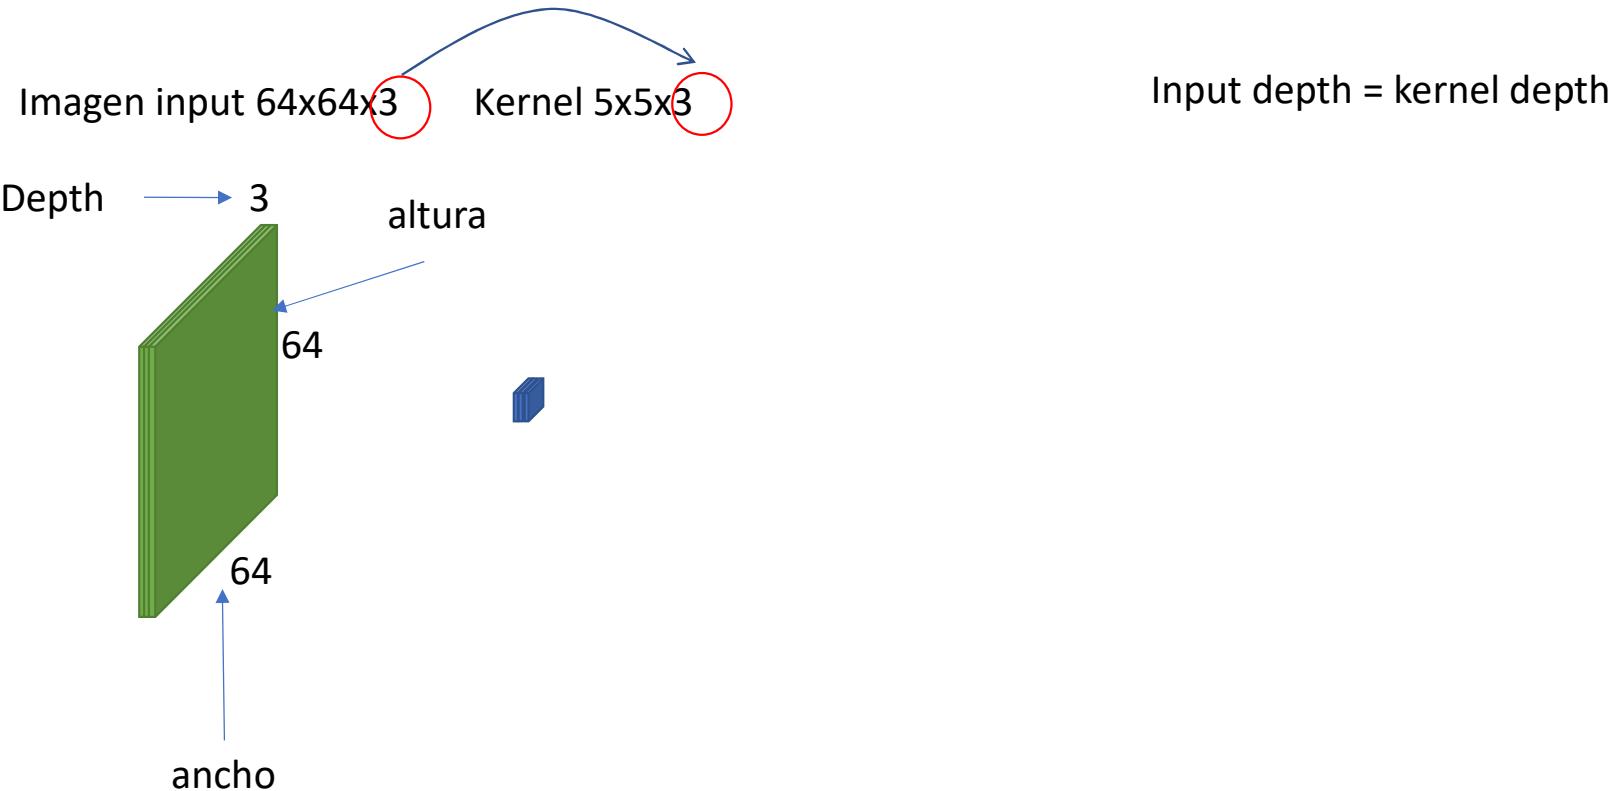
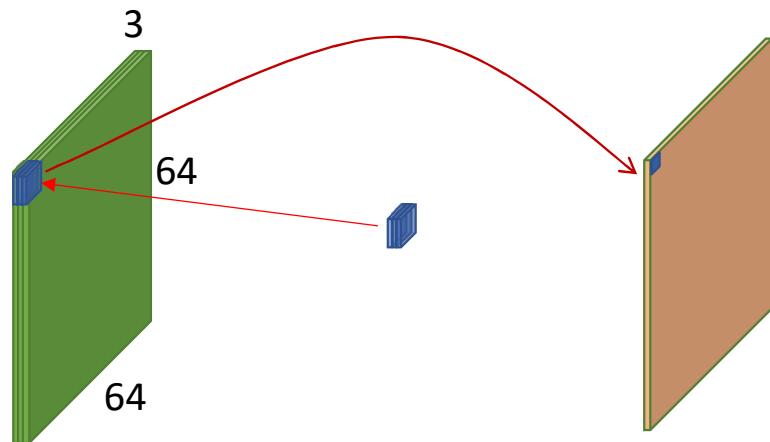


Imagen input 64x64x3

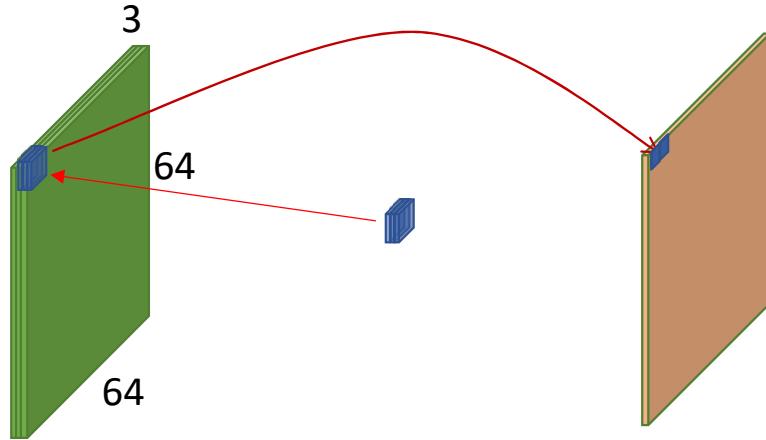
Kernel 5x5x3

Input depth = kernel depth



La convolución del kernel con el parche local  
en la imagen genera un solo valor

Imagen input  
64x64x3



Kernel 5x5x3

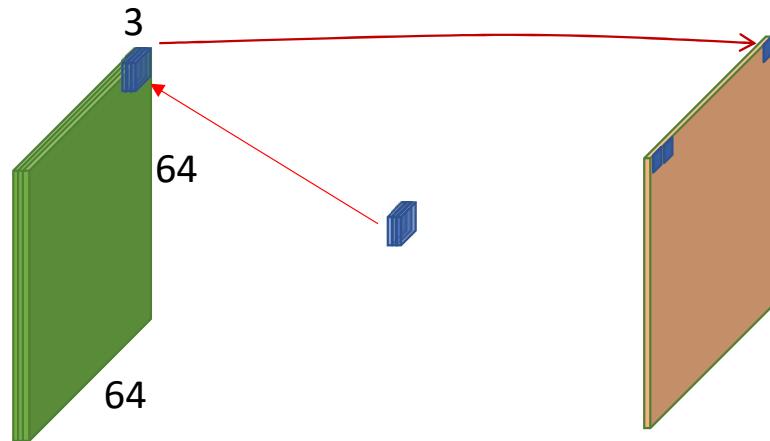
Input depth = kernel depth

La convolución del kernel con el parche local  
en la imagen genera un solo valor

Input image 64x64x3

Kernel 5x5x3

Input depth = kernel depth

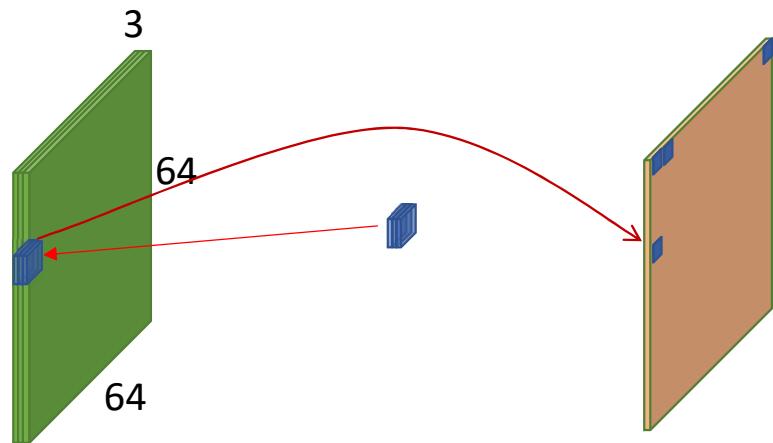


La convolución del kernel con el parche local  
en la imagen genera un solo valor

Input image 64x64x3

Kernel 5x5x3

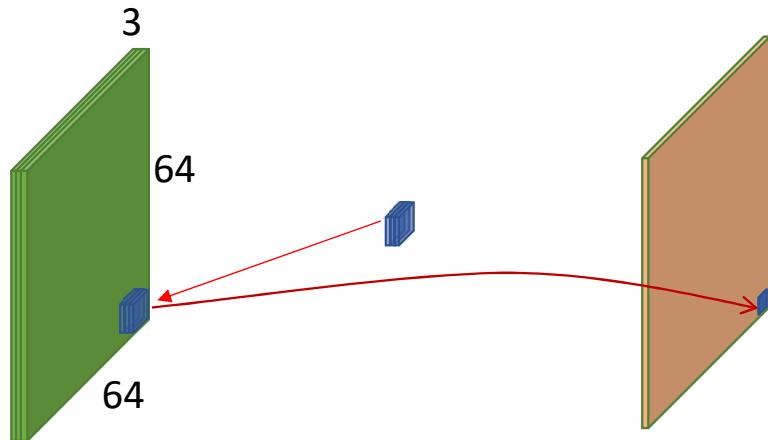
Input depth = kernel depth



La convolución del kernel con el parche local  
en la imagen genera un solo valor

Input image 64x64x3

Kernel 5x5x3



La convolución del kernel con el parche local en la imagen genera un solo valor

Input depth = kernel depth

Resultado final: mapa de activación

Mapa de activación: 60x60x1 (sin padding)

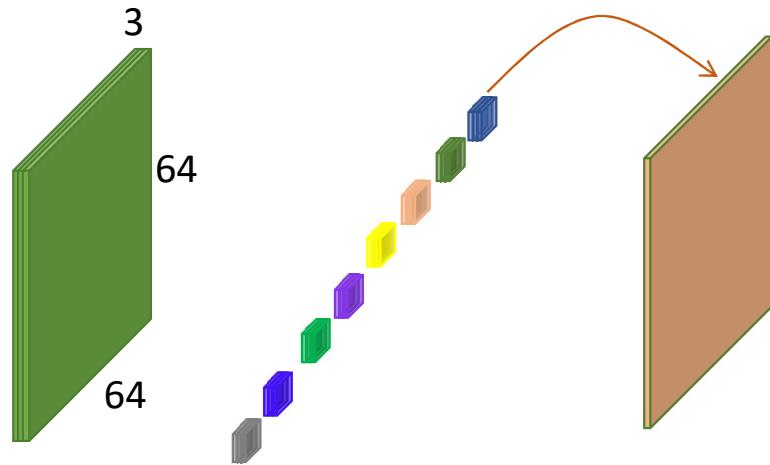
Mapa de activación: 64x64x1 (con padding=2)

Un kernel produce un mapa de profundidad 1

Input image 64x64x3

kernel 5x5x3

Input depth = kernel depth

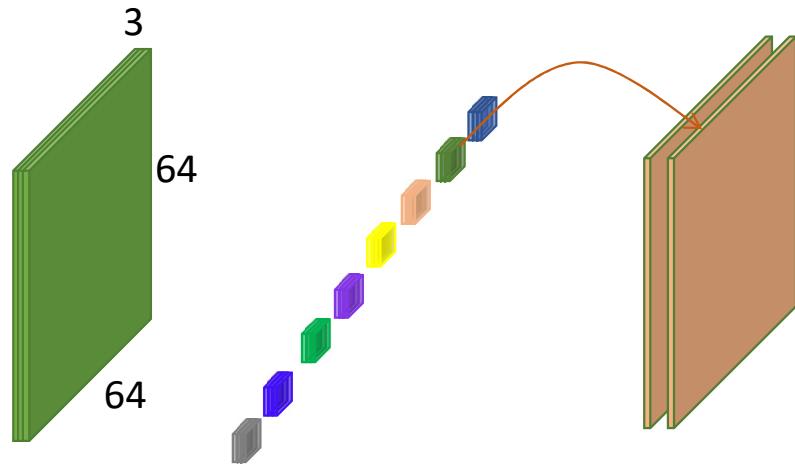


8 kernels of 5x5x3

Input image 64x64x3

kernel 5x5x3

Input depth = kernel depth

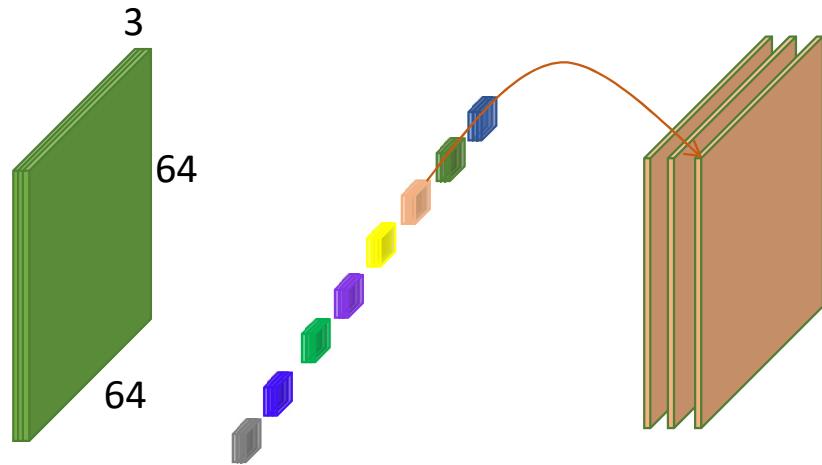


8 kernels of 5x5x3

Input image 64x64x3

kernel 5x5x3

Input depth = kernel depth

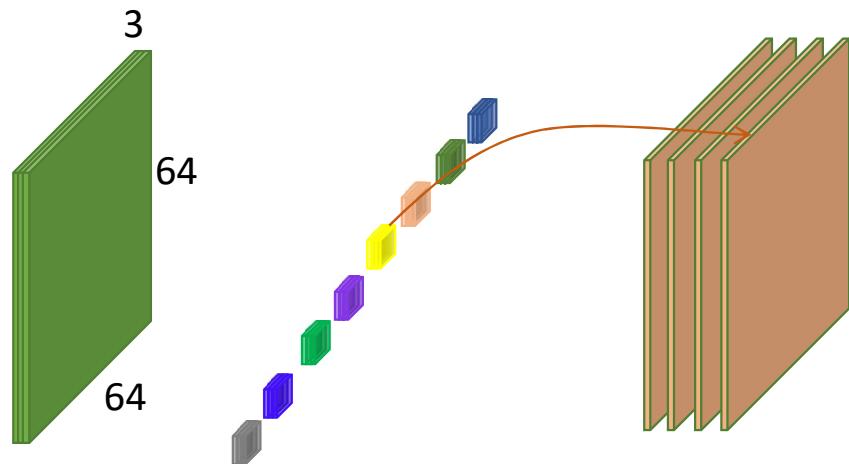


8 kernels of 5x5x3

Input image 64x64x3

kernel 5x5x3

Input depth = kernel depth

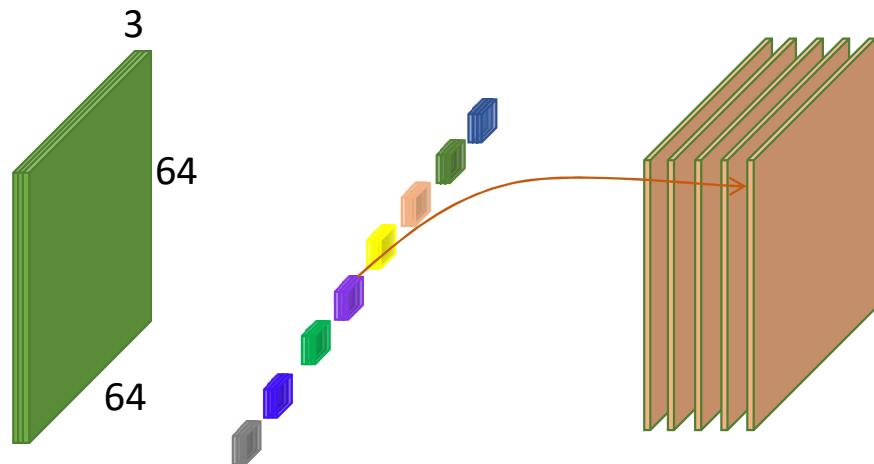


8 kernels of 5x5x3

Input image 64x64x3

kernel 5x5x3

Input depth = kernel depth

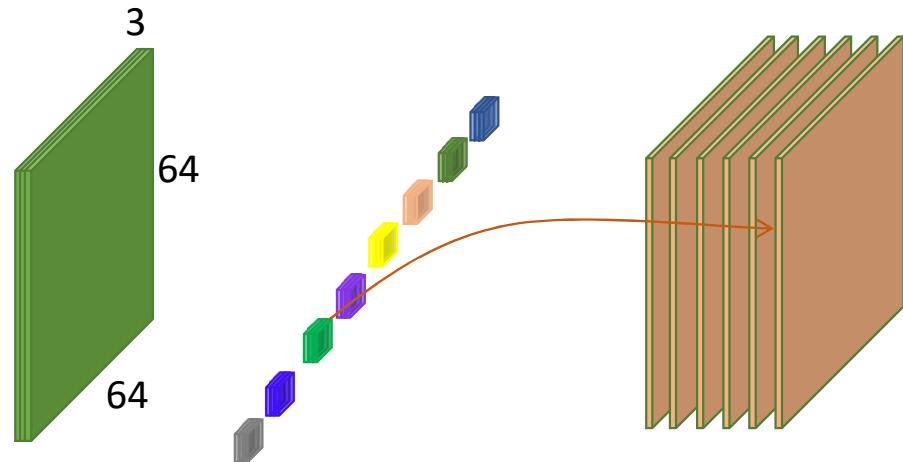


8 kernels of 5x5x3

Input image 64x64x3

kernel 5x5x3

Input depth = kernel depth

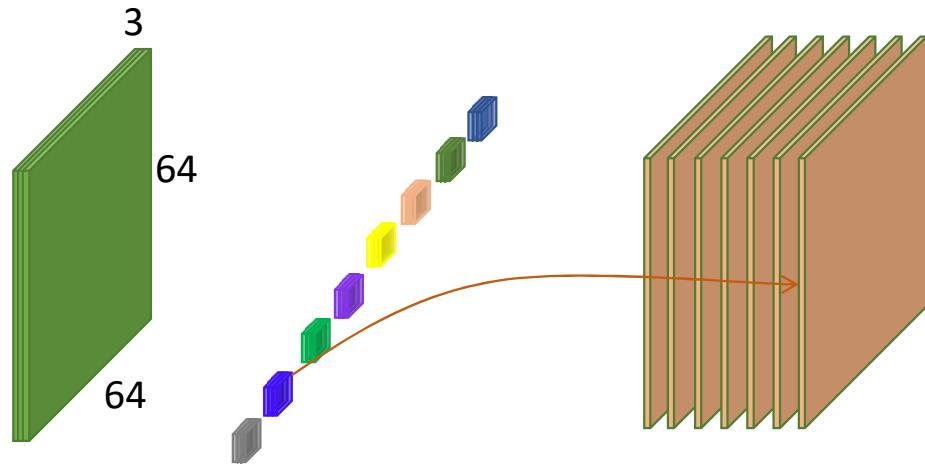


8 kernels of 5x5x3

Input image 64x64x3

kernel 5x5x3

Input depth = kernel depth

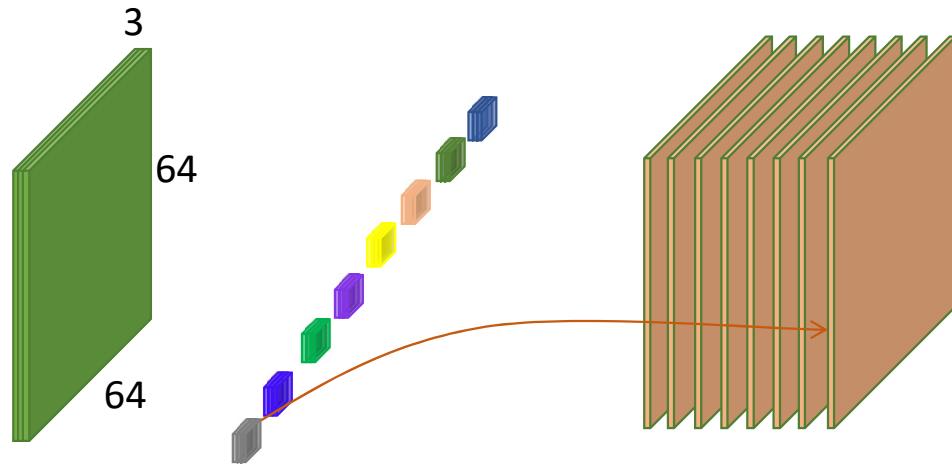


8 kernels of 5x5x3

Input image 64x64x3

kernel 5x5x3

Input depth = kernel depth



Salida es *volumen* de 64x64x8

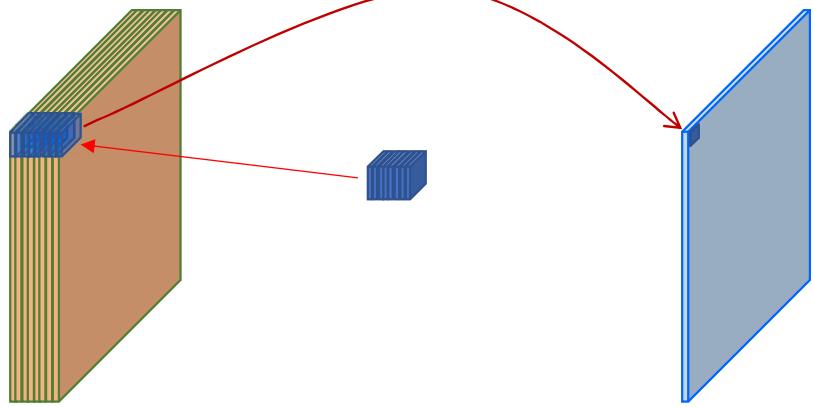
### Primera capa convolucional

- Entrada: volumen de 64x64x3
- Kernels: 8 de 5x5x3 con padding=1
- Salida: volumen de 64x64x8

## Segunda capa convolucional

Input: volumen  $64 \times 64 \times 8$

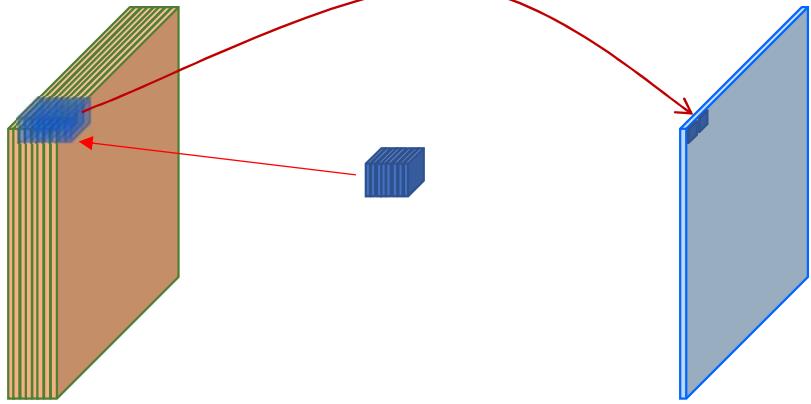
Kernel: volumen  $5 \times 5 \times 8$



## Segunda capa convolucional

Input: volume  $64 \times 64 \times 8$

Kernel: volume  $5 \times 5 \times 8$



# Deep Learning

*Clasificación de  
imágenes*



# Introducción

- Problema de asignar una etiqueta a una imagen

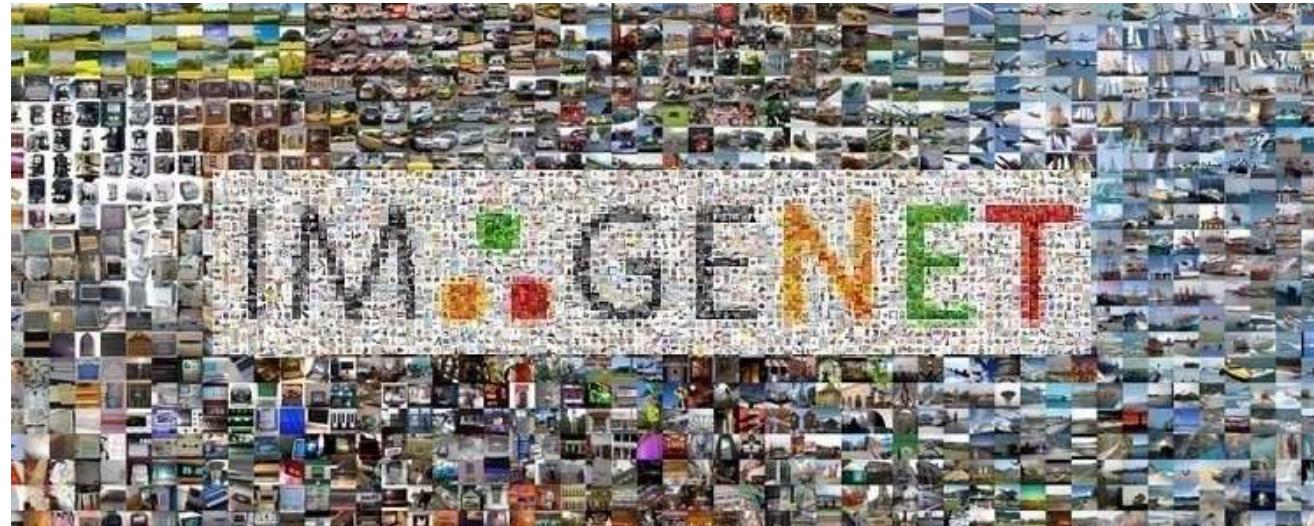
**Classification**



CAT

# Introducción

- Para entrenar modelos profundos, necesitamos datasets grandes:  
ImageNet
- +14M imágenes, +21,000 clases
- No todo el dataset es útil. Se usa el Imagenet Large Scale Visual Recognition Challenge dataset (ILSVR)

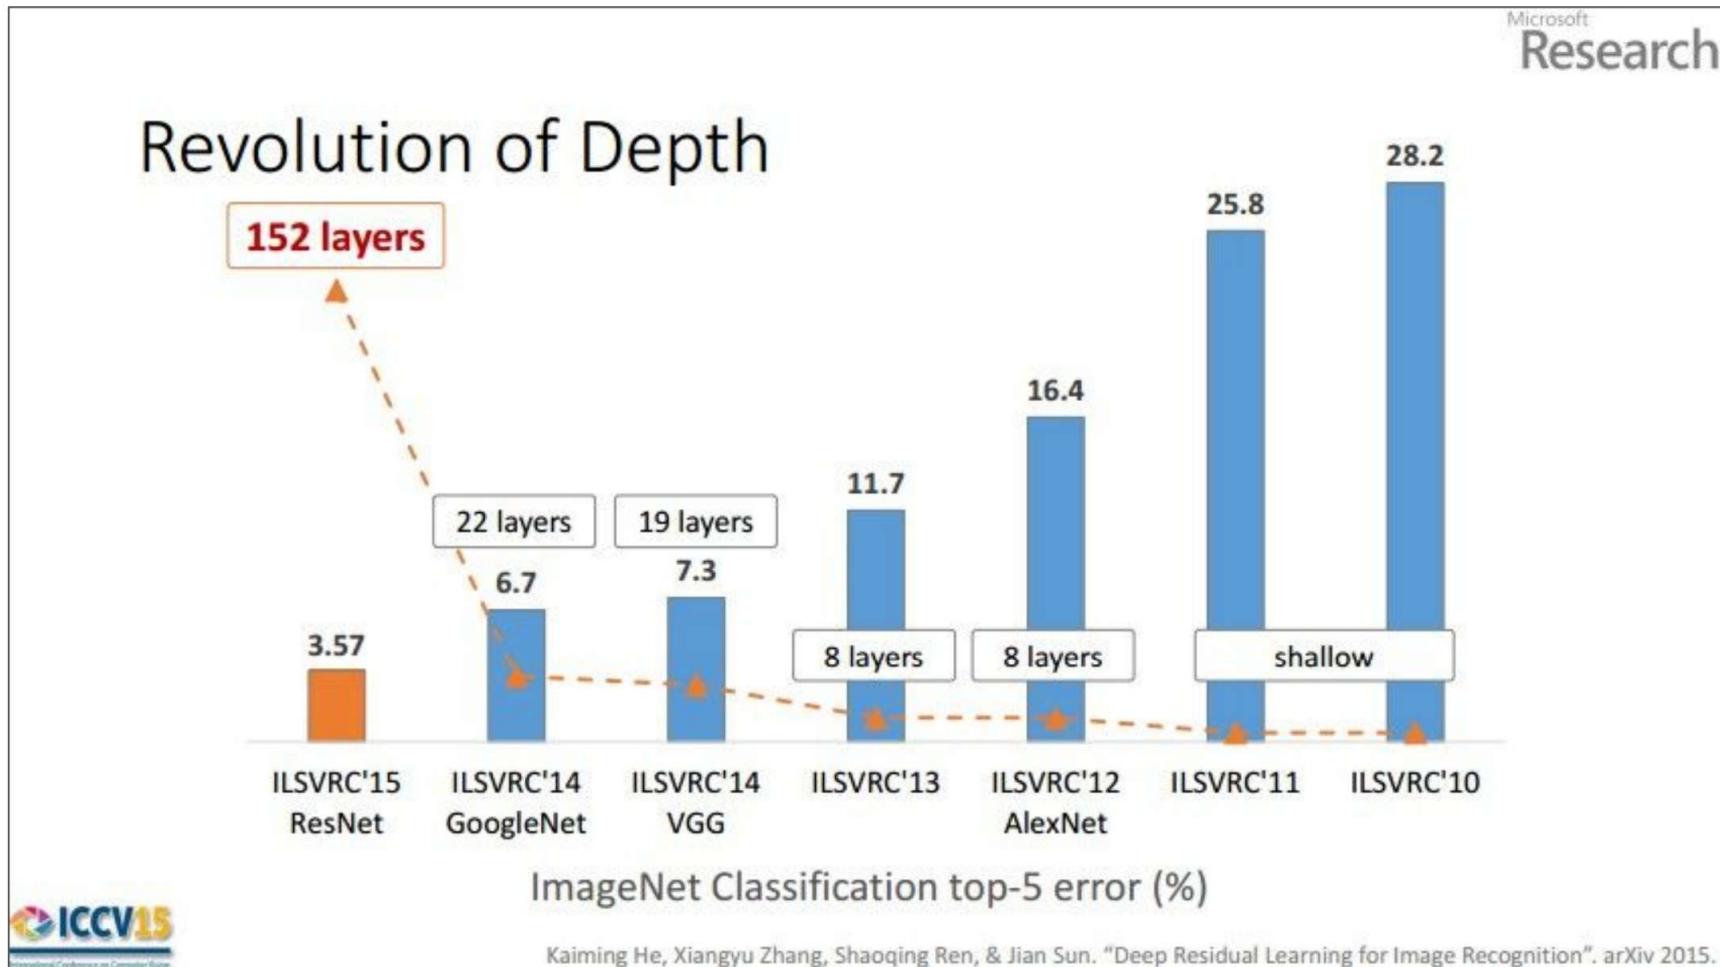


# Introducción

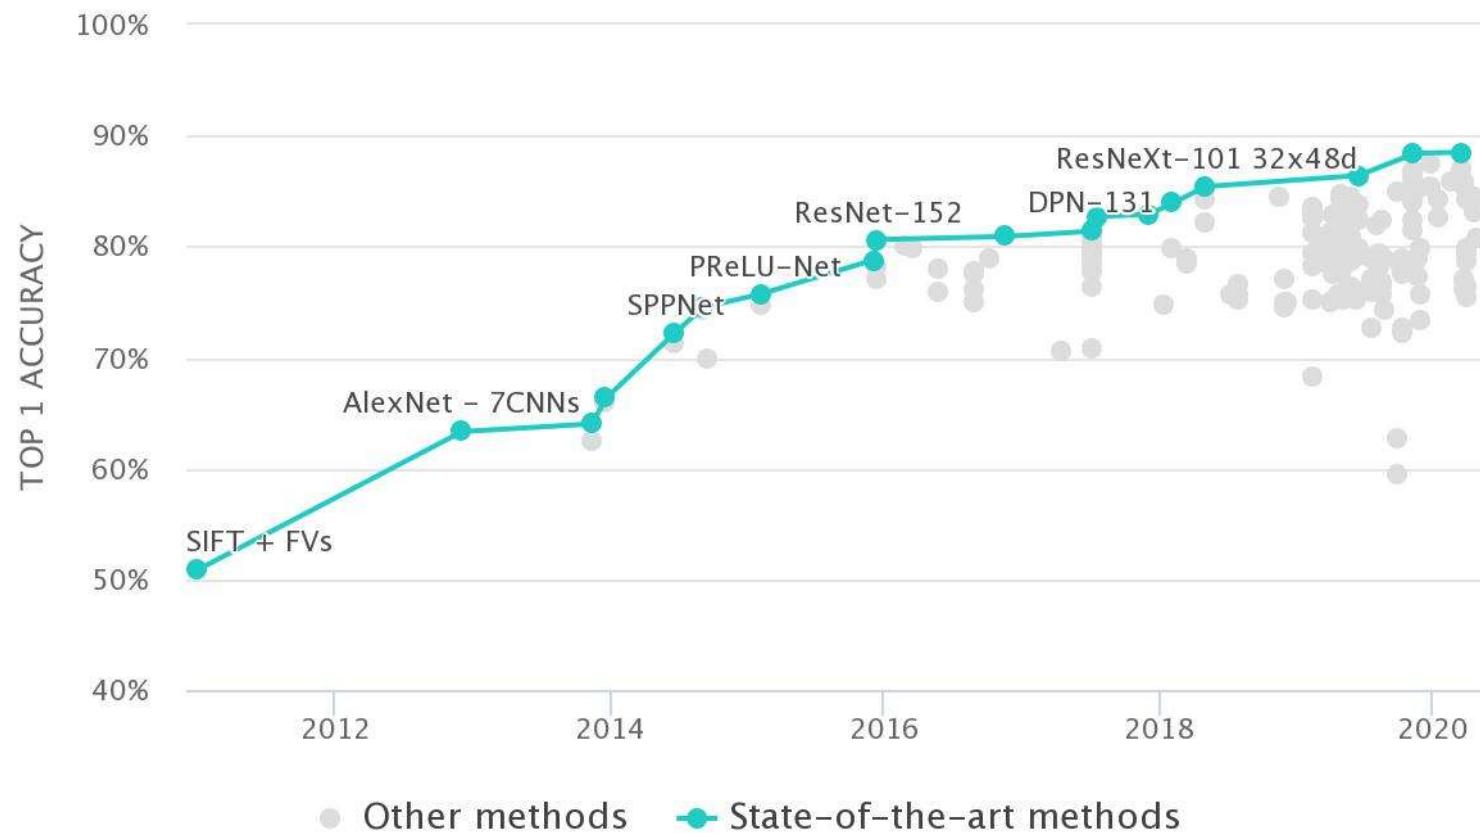
- ILSVR dataset
  - Usado para competiciones desde 2010
  - Num. imágenes: 1.2 Millones (200K test)
  - Num. clases: 1000
- Métricas de evaluación
  - Top-1 Accuracy: Ratio de imágenes de test con clase correcta con mayor probabilidad.
  - Top-5 Accuracy: Ratio de imágenes de test con clase correcta entre las 5 predicciones con mayor probabilidad.

<http://www.image-net.org/challenges/LSVRC/>

# La competición



# Estado reciente



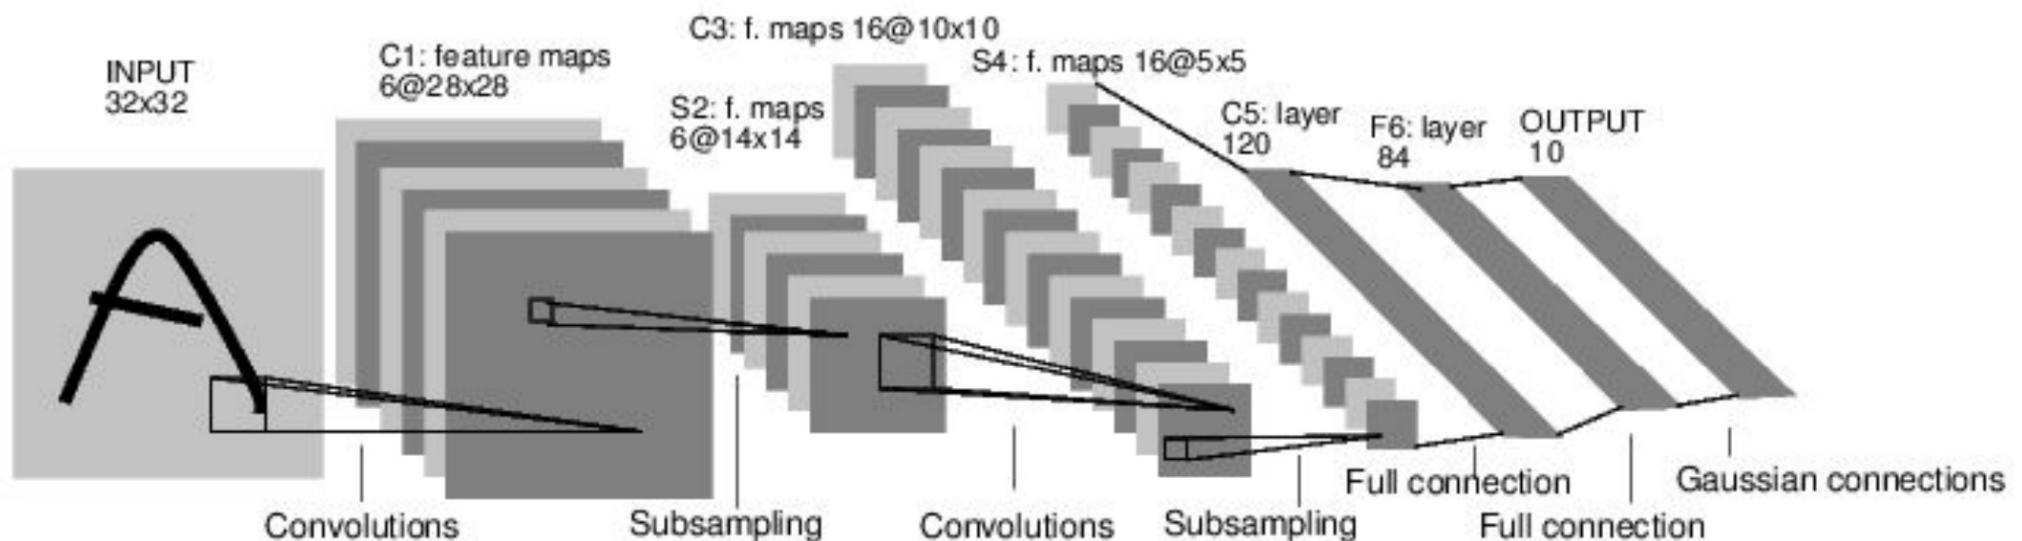
<https://paperswithcode.com/sota/image-classification-on-imagenet>

# Deep Learning

*Arquitecturas  
comunes*



# LeNet-5

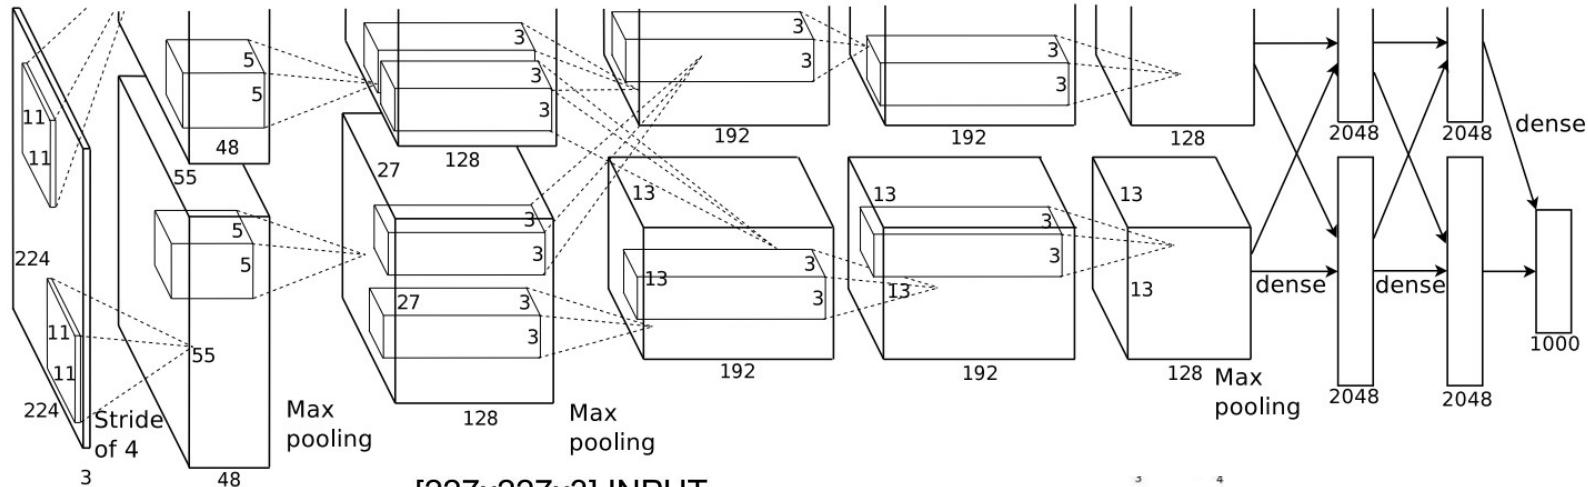


Conv filters were 5x5, applied at stride 1

Subsampling (Pooling) layers were 2x2 applied at stride 2

i.e. architecture is [CONV-POOL-CONV-POOL-CONV-FC]

# AlexNet



[227x227x3] INPUT

[55x55x96] CONV1: 96 11x11 filters at stride 4, pad 0

[27x27x96] MAX POOL1: 3x3 filters at stride 2

[27x27x96] NORM1: Normalization layer

[27x27x256] CONV2: 256 5x5 filters at stride 1, pad 2

[13x13x256] MAX POOL2: 3x3 filters at stride 2

[13x13x256] NORM2: Normalization layer

[13x13x384] CONV3: 384 3x3 filters at stride 1, pad 1

[13x13x384] CONV4: 384 3x3 filters at stride 1, pad 1

[13x13x256] CONV5: 256 3x3 filters at stride 1, pad 1

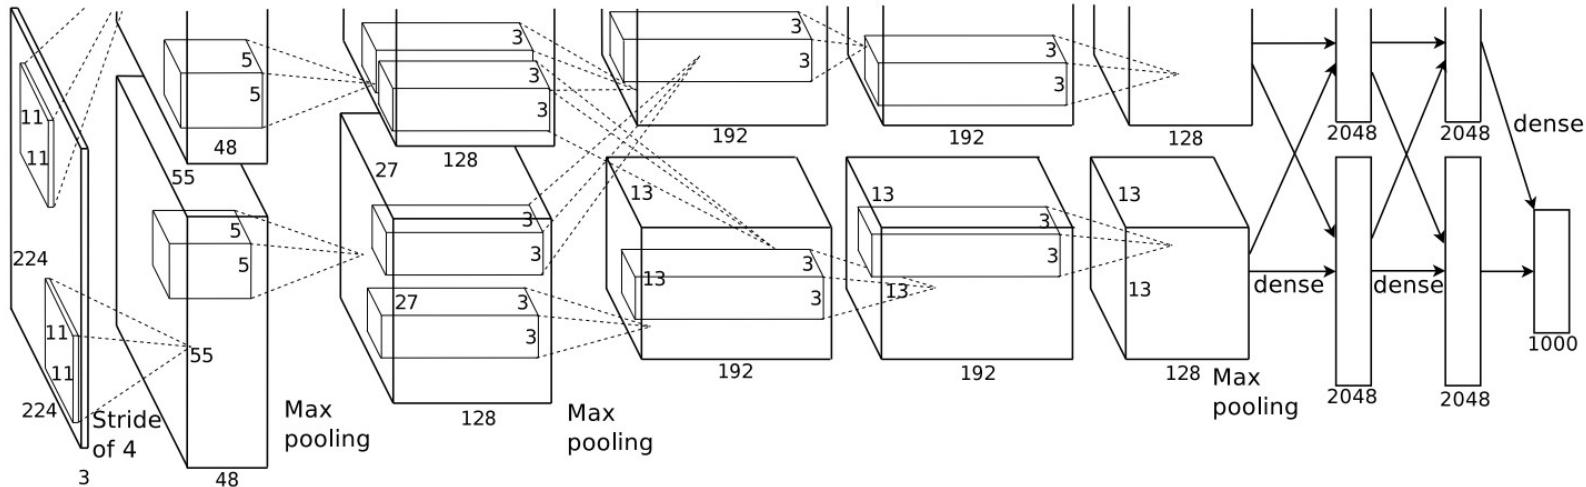
[6x6x256] MAX POOL3: 3x3 filters at stride 2

[4096] FC6: 4096 neurons

[4096] FC7: 4096 neurons

[1000] FC8: 1000 neurons (class scores)

# AlexNet



## Details/Retrospectives:

- first use of ReLU
- used Norm layers (not common anymore)
- heavy data augmentation
- dropout 0.5
- batch size 128
- SGD Momentum 0.9
- Learning rate 1e-2, reduced by 10 manually when val accuracy plateaus
- L2 weight decay 5e-4
- 7 CNN ensemble: 18.2% -> **15.4%**

# VGGNet

[Simonyan and Zisserman, 2014]

Only 3x3 CONV stride 1, pad 1  
and 2x2 MAX POOL stride 2

best model

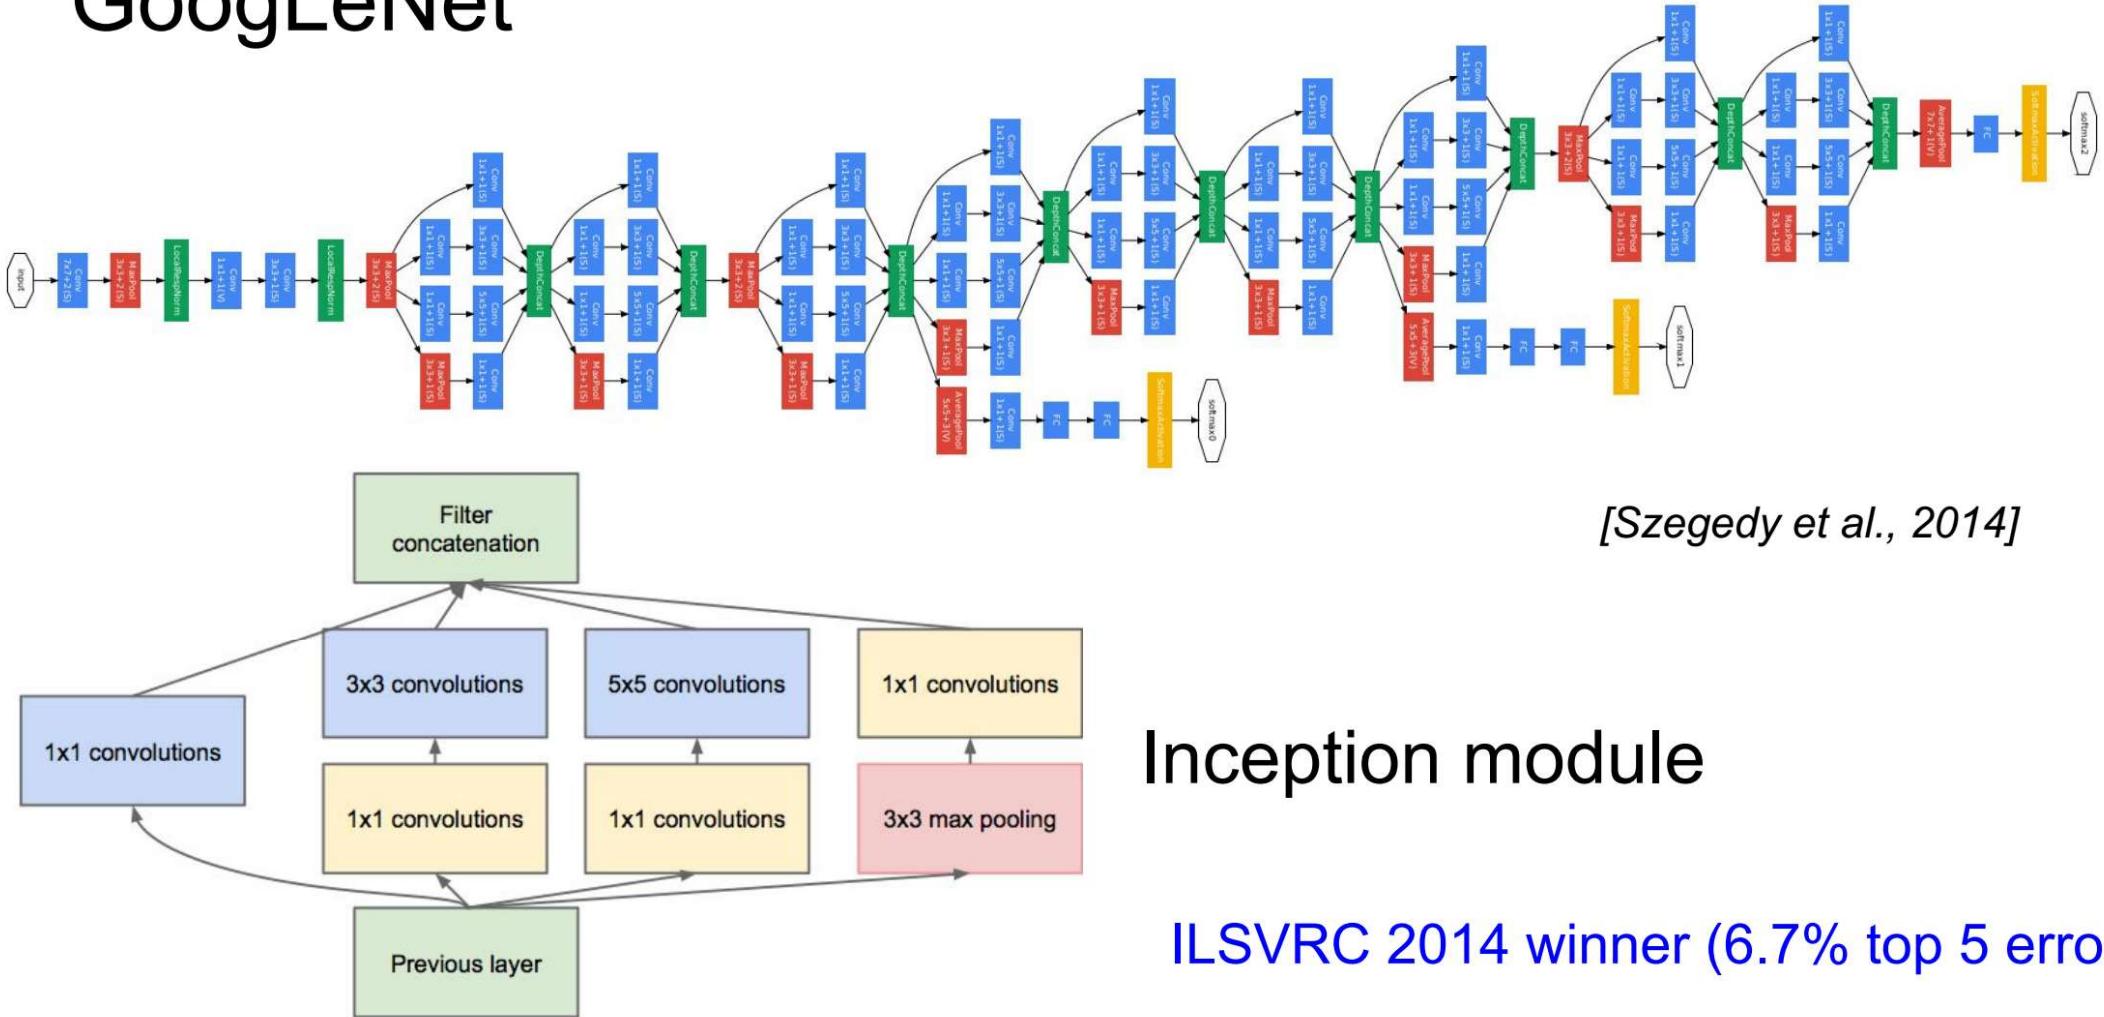
7.3% top 5 error

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 <b>LRN</b>	conv3-64 <b>conv3-64</b>	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 <b>conv3-128</b>	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 <b>conv1-256</b>	conv3-256 conv3-256 <b>conv3-256</b>	conv3-256 conv3-256 conv3-256 <b>conv3-256</b>
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 <b>conv1-512</b>	conv3-512 conv3-512 <b>conv3-512</b>	conv3-512 conv3-512 conv3-512 <b>conv3-512</b>
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 <b>conv1-512</b>	conv3-512 conv3-512 <b>conv3-512</b>	conv3-512 conv3-512 conv3-512 <b>conv3-512</b>
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

Table 2: Number of parameters (in millions).

Network	A,A-LRN	B	C	D	E
Number of parameters	133	133	134	138	144

# GoogLeNet



# ResNet [He et al., 2015]

ILSVRC 2015 winner (3.6% top 5 error)

## Revolution of Depth

AlexNet, 8 layers  
(ILSVRC 2012)



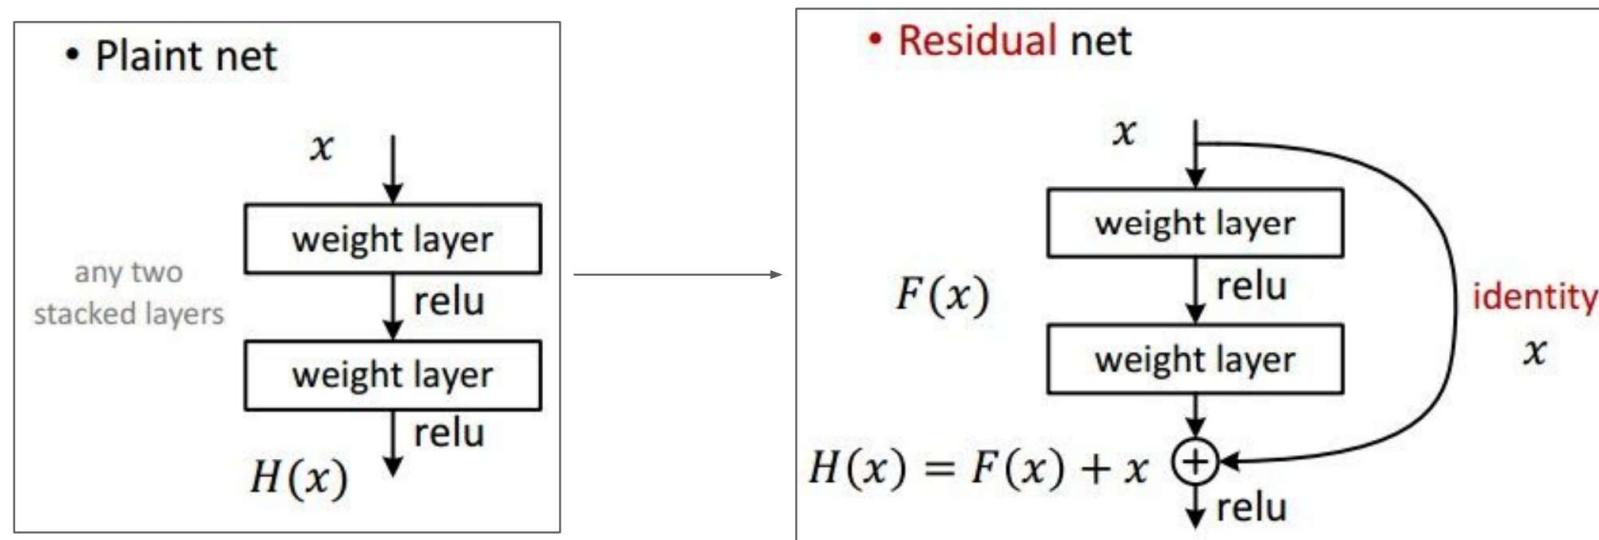
VGG, 19 layers  
(ILSVRC 2014)



ResNet, 152 layers  
(ILSVRC 2015)



# ResNet

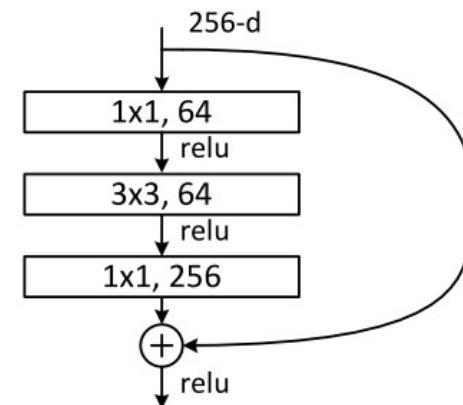
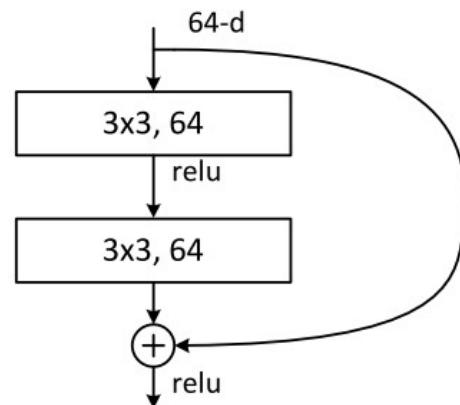


## ResNet [He et al., 2015]

- Batch Normalization after every CONV layer
- Xavier/2 initialization from He et al.
- SGD + Momentum (0.9)
- Learning rate: 0.1, divided by 10 when validation error plateaus
- Mini-batch size 256
- Weight decay of 1e-5
- No dropout used

# Resnet

- Para redes más profundas, es necesario reducir las computaciones.
- Conexiones en cuello de botella



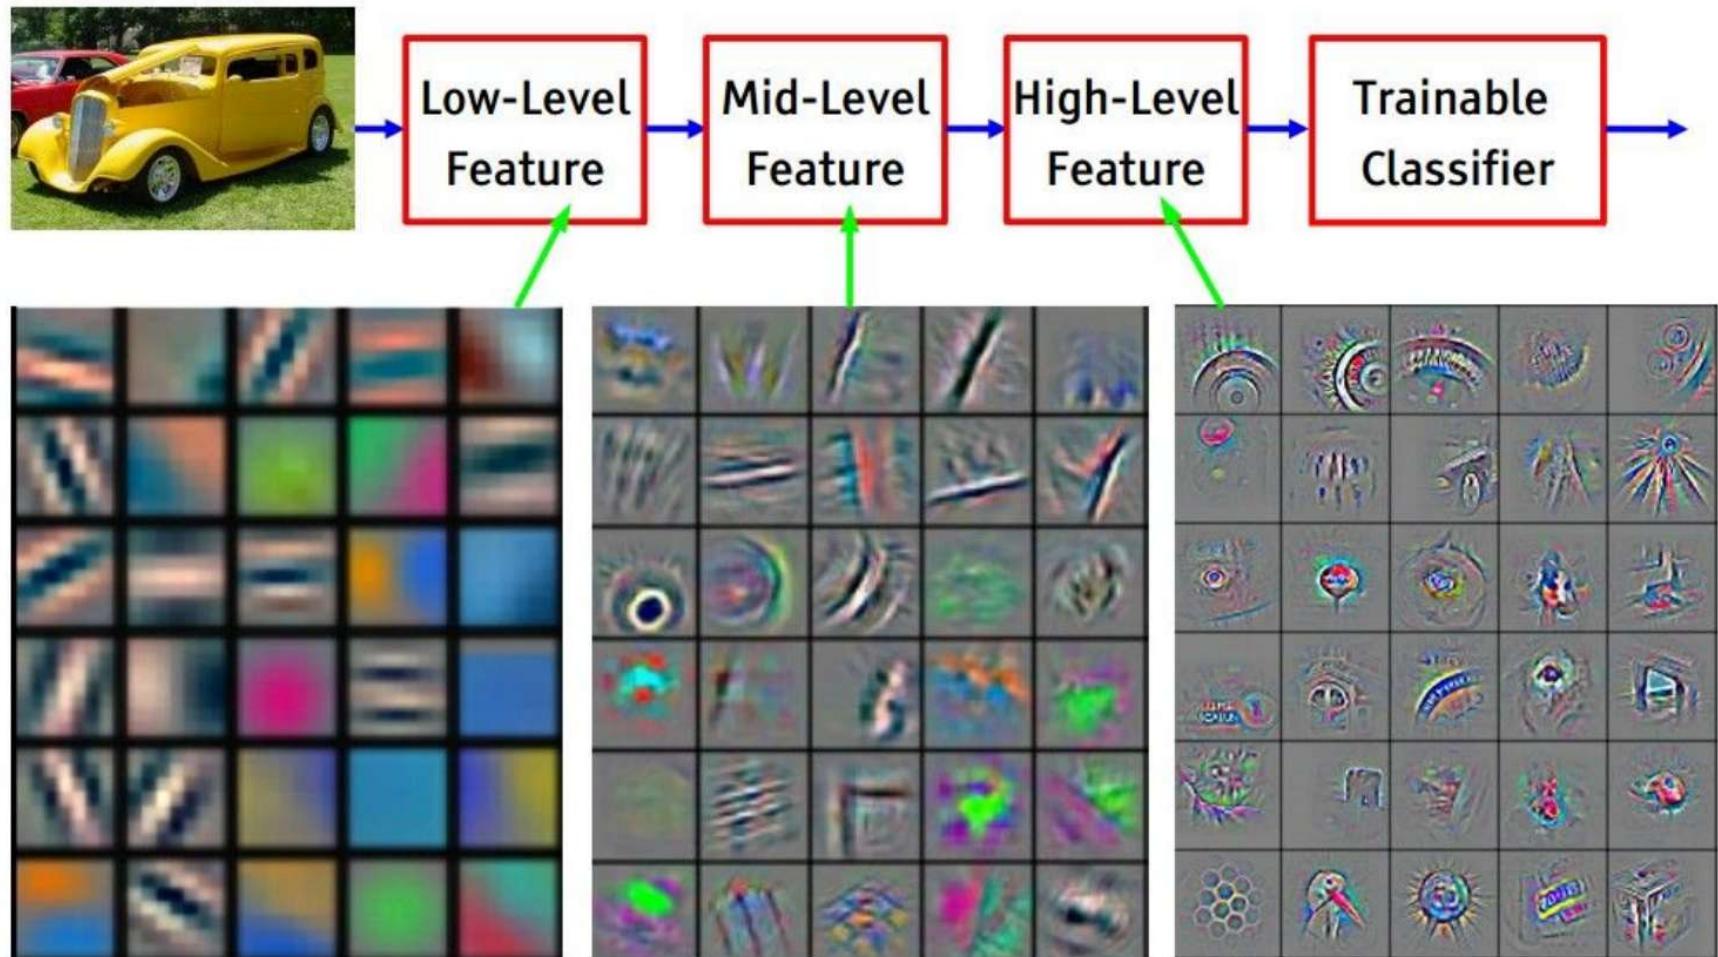
# ResNet [He et al., 2015]

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112			7×7, 64, stride 2		
conv2_x	56×56	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		$1.8 \times 10^9$	$3.6 \times 10^9$	$3.8 \times 10^9$	$7.6 \times 10^9$	$11.3 \times 10^9$

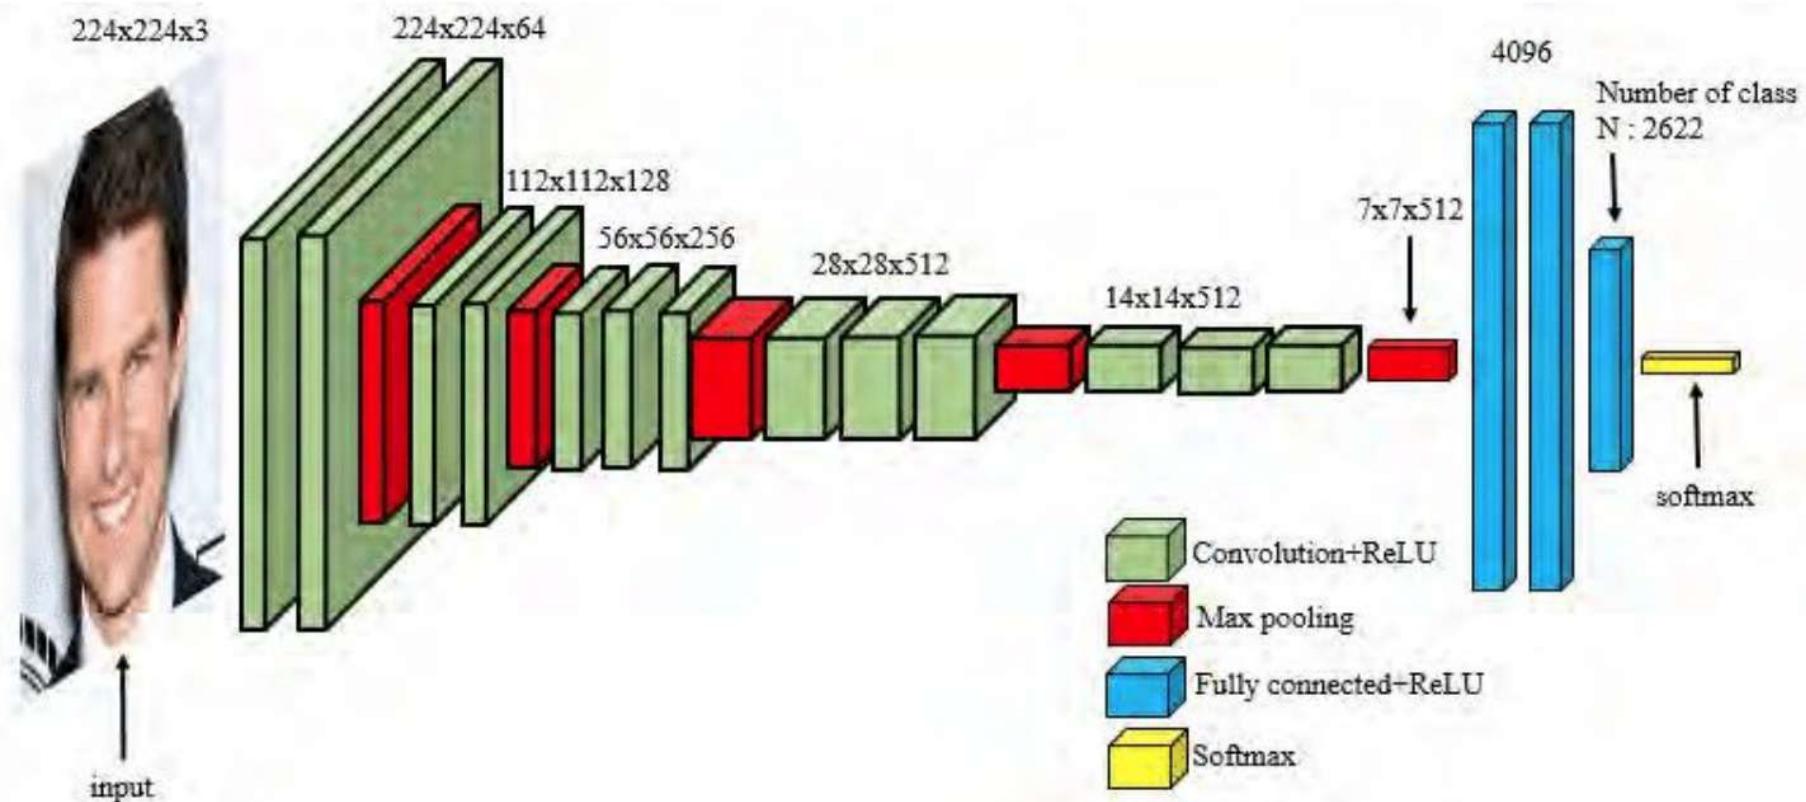
# Deep Learning

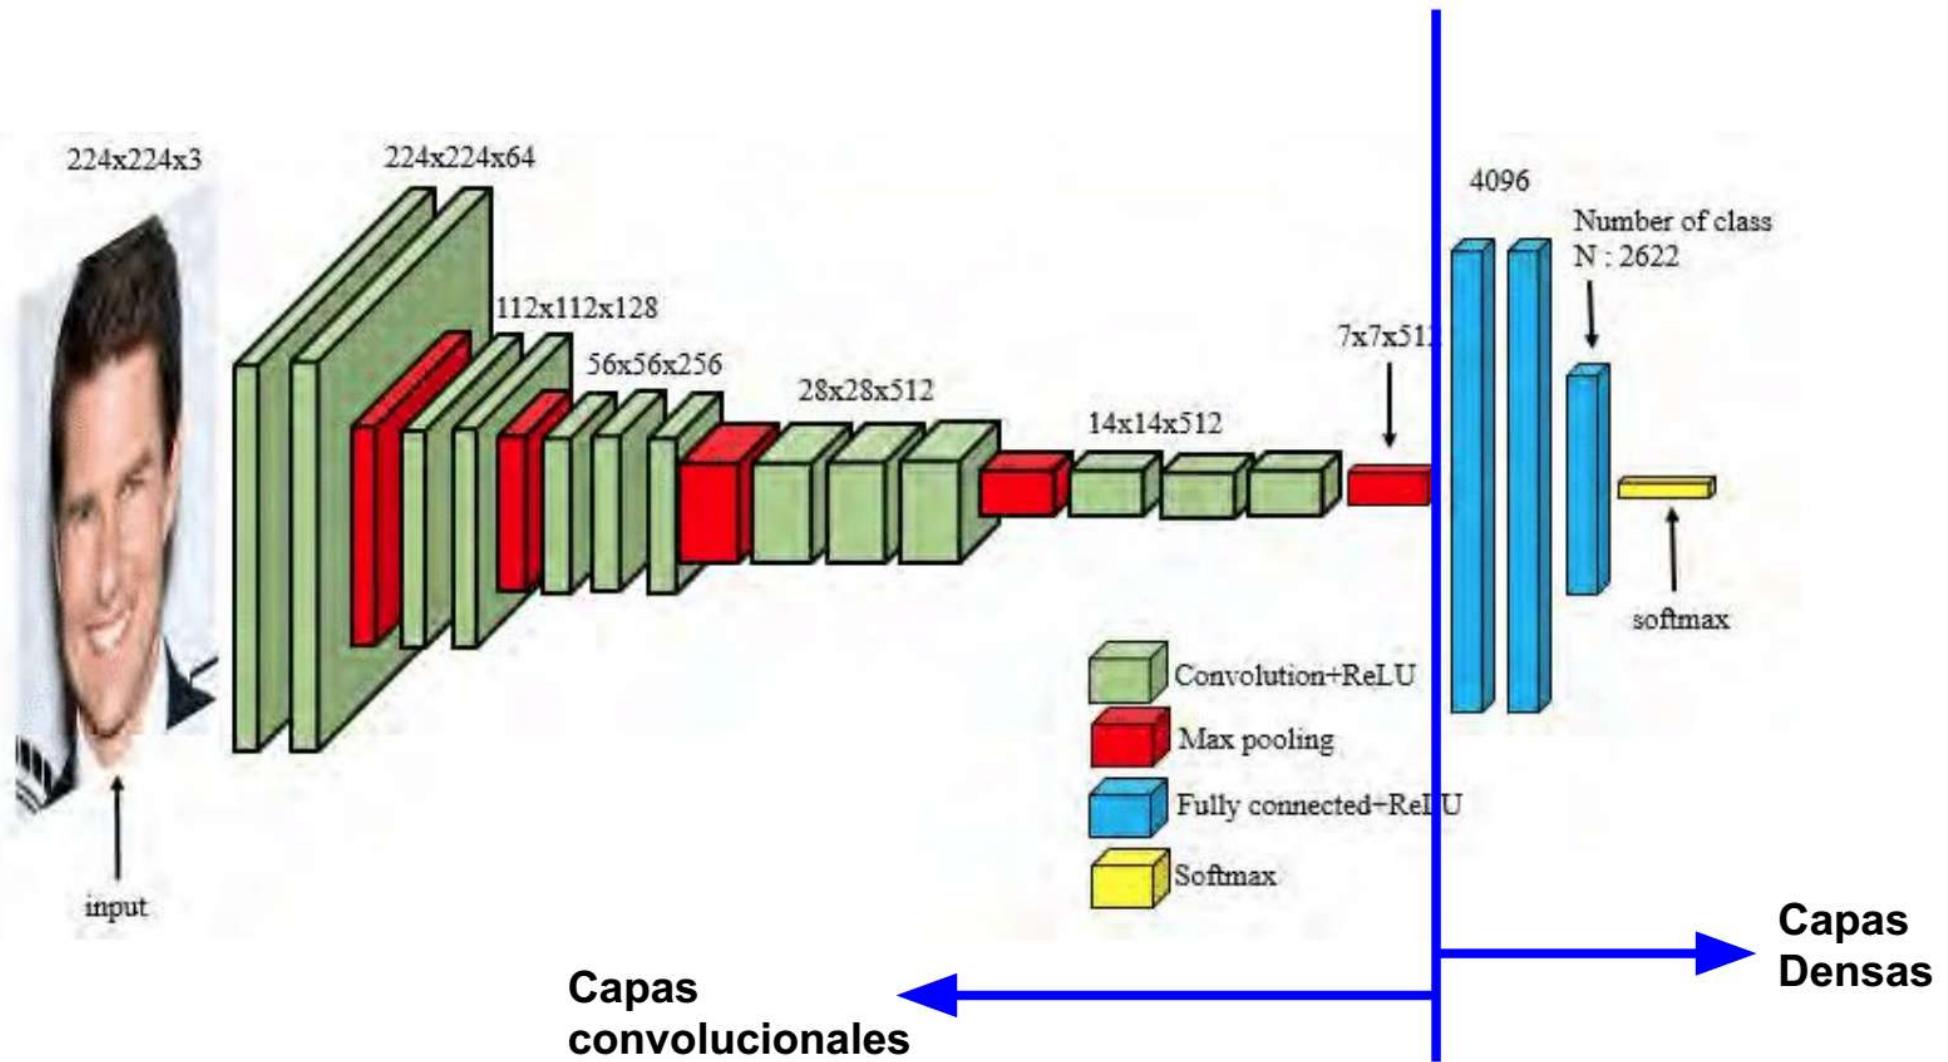
*Transfer Learning*

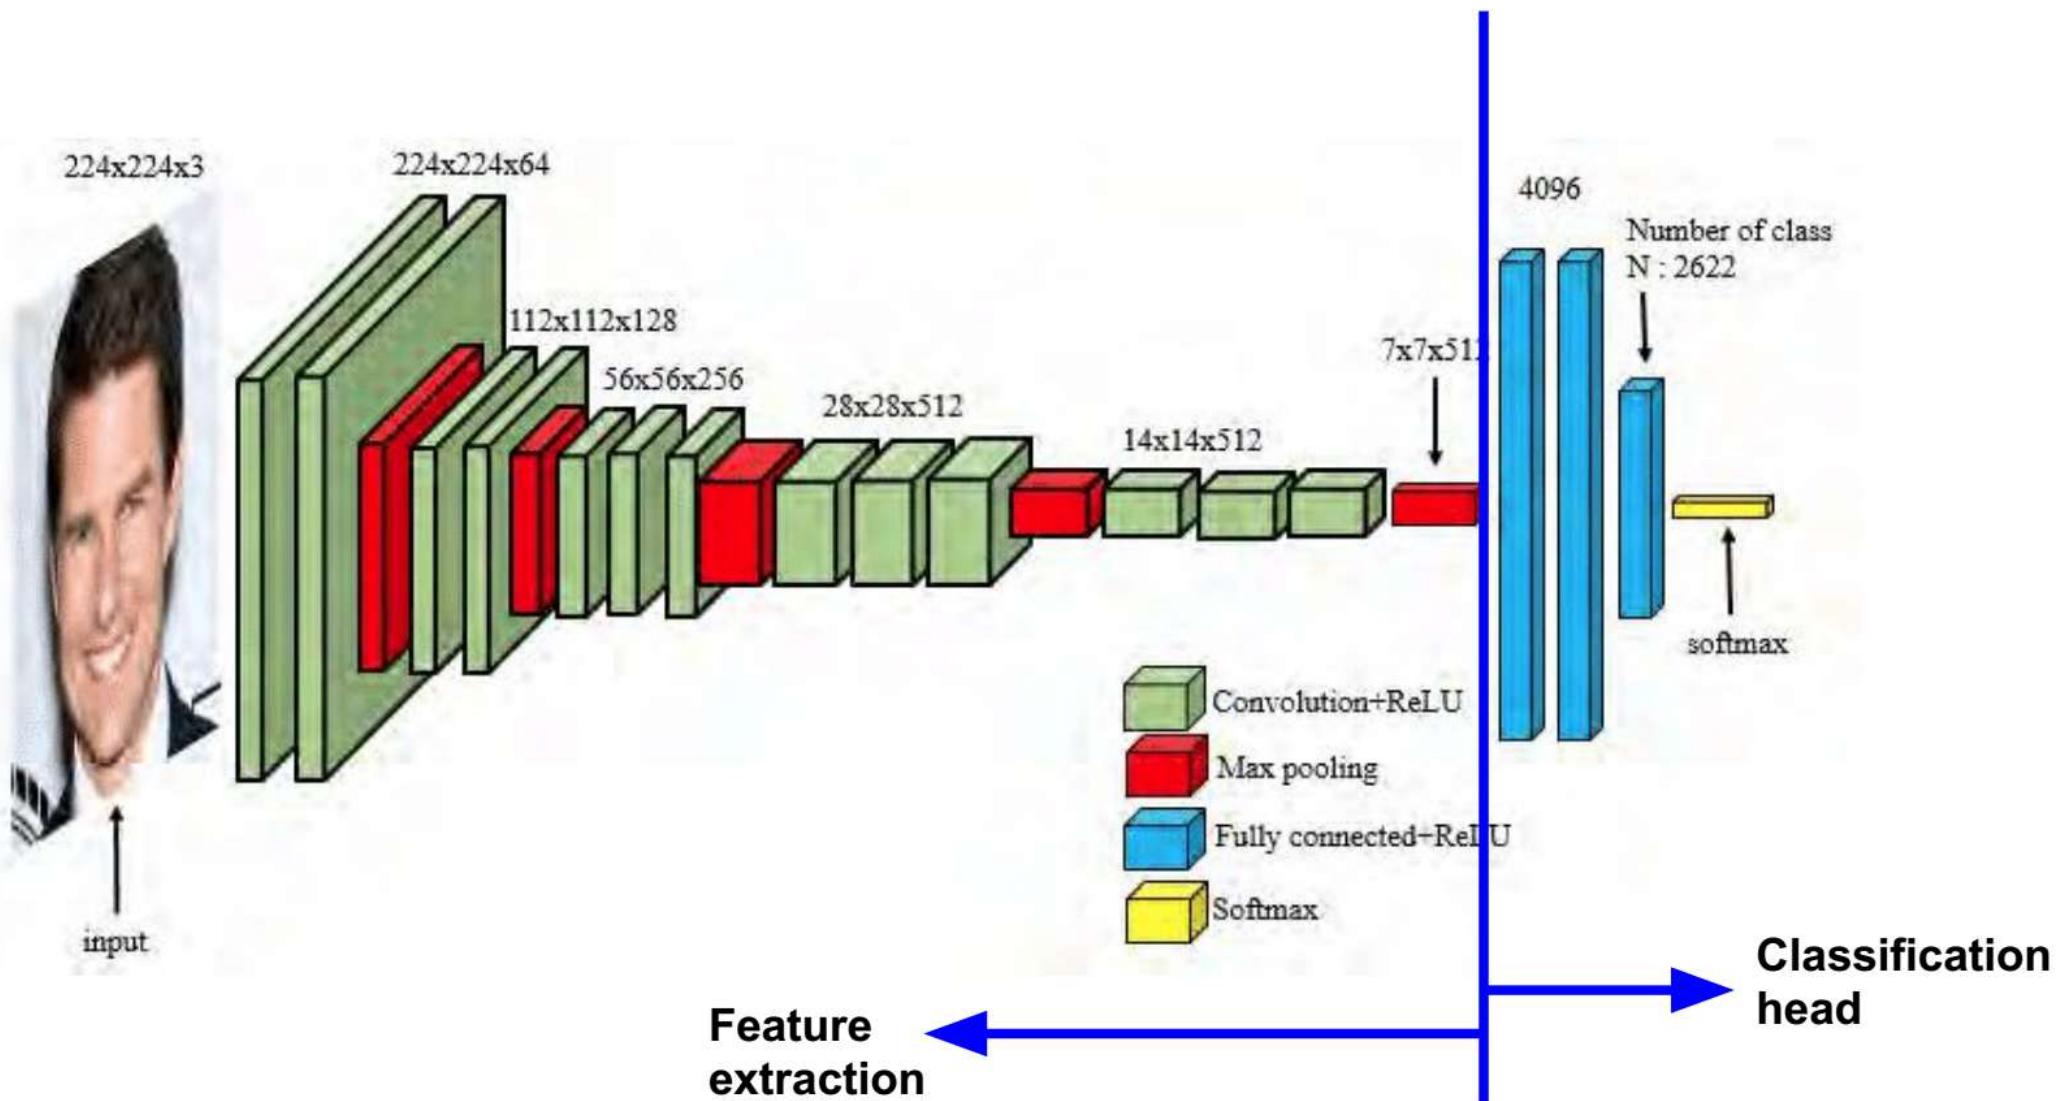




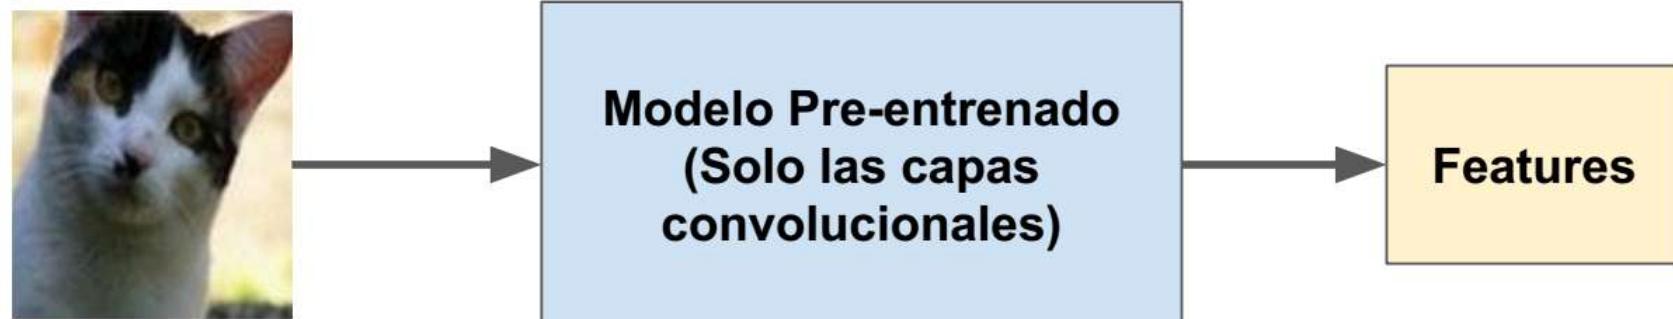
Feature visualization of convolutional net trained on ImageNet from [Zeiler & Fergus 2013]



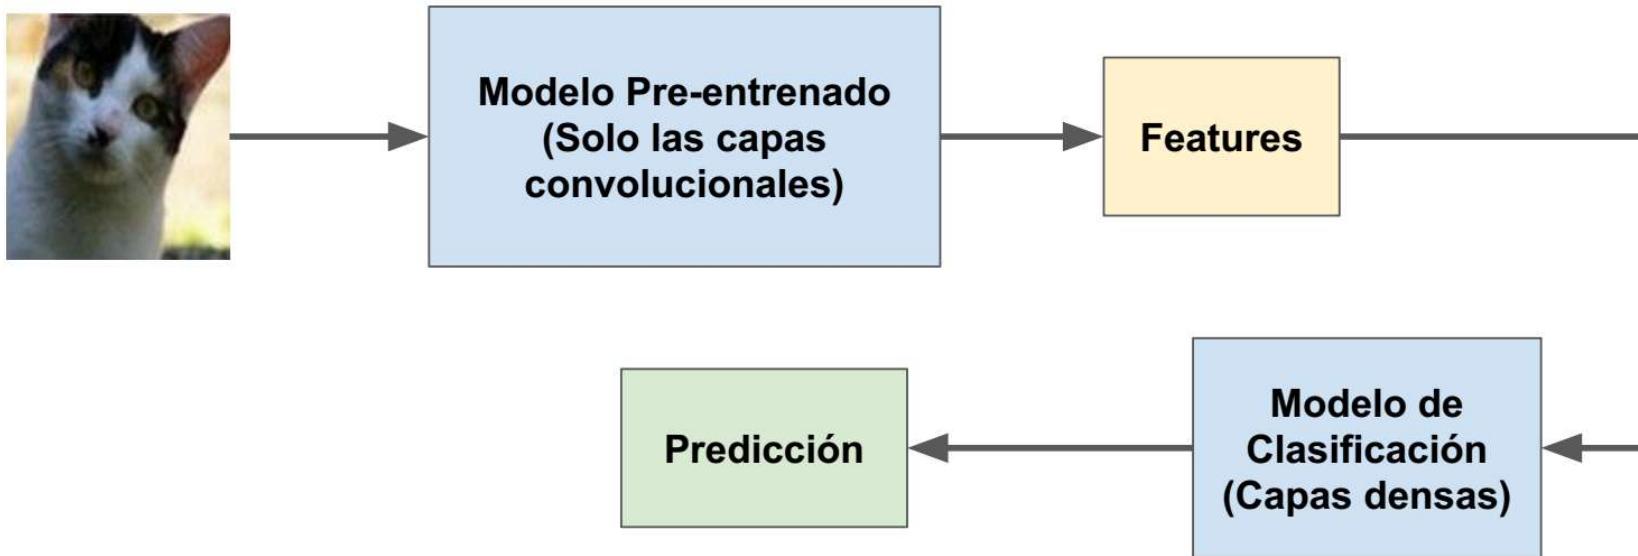




# Transfer Learning



# Transfer Learning



# Transfer Learning - entrenamiento

